

# Analyse des Données Longitudinales : Rapport de Projet

HASSAK Arezki, SIDIBE Ablaye Sow  
Monsieur WILLER Thomas

Décembre 2024

# 1. Présentation de la question d'intérêt et des données

## Objectifs du projet

L'égalité salariale entre hommes et femmes est une question qui a longtemps fait l'objet de débats dans de nombreuses sociétés, y compris dans les pays développés. Malgré les avancées en matière d'égalité des sexes dans le monde du travail, des inégalités persistent, même parmi les individus les plus qualifiés. En France, la situation des diplômés d'enseignement supérieur est souvent perçue comme une illustration des efforts réussis pour réduire les écarts entre hommes et femmes en termes de qualification. Cependant, plusieurs études montrent que des écarts de salaires entre les sexes demeurent, même au sein de groupes d'individus très qualifiés, comme ceux ayant atteint un niveau d'éducation supérieur à Bac+5.

Dans ce contexte, l'objectif de cette étude est d'analyser l'impact du genre sur l'évolution salariale des individus ayant obtenu un diplôme supérieur à Bac+5, en utilisant les données de l'enquête "Génération 1998 à 10 ans" du CEREQ. En étudiant cette population spécifique, nous chercherons à comprendre si des disparités salariales entre hommes et femmes existent encore, même au sein de cette catégorie de diplômés qualifiés.

## Problématique

Les études sur l'égalité salariale montrent que, bien que des progrès aient été réalisés en matière d'accès à l'éducation pour les femmes, des écarts de salaires entre les sexes persistent dans de nombreux secteurs professionnels. En particulier, dans des groupes de travailleurs hautement qualifiés (Bac+5 et plus), les femmes continuent de rencontrer des obstacles dans l'accès à des salaires équitables. Ainsi, la question centrale de cette étude est : "Quel est l'impact du genre sur l'évolution salariale des individus ayant un niveau d'éducation Bac+5 ou plus dans l'Ile-de-France ?"

En d'autres termes, malgré un diplôme commun, est-ce que des différences salariales sont encore observées entre hommes et femmes au fil du temps ?

## Hypothèses

Dans le cadre de cette étude, nous formulons les hypothèses suivantes:

**Hypothèse 1 :** L'évolution salariale des individus est globalement positive au fil du temps. Cependant, malgré un niveau de Éducation équivalent (*Bac+5 ou plus*), les femmes connaissent une progression salariale inférieure à celle des hommes.

**Hypothèse 2 :** Le genre exerce un impact significatif sur l'évolution salariale des individus.

## Descriptif des Jeux de Données

Pour cette étude, nous avons travaillé à partir de la table de données provenant de l'enquête *Génération 1998 à 10 ans* réalisée par le CEREQ. Afin d'adapter cette base de données aux besoins spécifiques de notre analyse, plusieurs étapes de traitement ont été réalisées à l'aide de **SAS**. Ces étapes sont détaillées ci-dessous:

1. **Filtrage des individus** : Nous avons restreint l'analyse aux individus ayant un niveau de qualification supérieur ou égal à **Bac+5**. De plus, seuls les individus résidant dans la région **Île-de-France** ont été retenus afin de garantir une population géographiquement homogène.
2. **Suppression des observations manquantes** : Les individus ayant au moins un **salaire non renseigné** (valeurs manquantes) ont été supprimés pour assurer la qualité des analyses.
3. **Traitement des individus atypiques** : Les observations identifiées comme **atypiques**, notamment celles présentant des valeurs salariales aberrantes, ont été exclues à l'aide de critères statistiques robustes définis en fonction de la distribution des données.
4. **Transformation en table longitudinale** : Les données, initialement structurées par individu, ont été converties en une **table longitudinale**. Chaque ligne de cette table représente une observation d'un individu à un moment donné, permettant ainsi de suivre l'évolution temporelle des salaires.

Après ces transformations, nous avons obtenu une table nettoyée et prête à l'analyse. Voici un aperçu des variables d'intérêt, issu de la commande `PROC CONTENTS` sous SAS :

## Explications des variables d'Intérêt

- **IDENT** : Identifiant unique pour chaque individu dans la base de données.
- **Q1** : Genre de l'individu (par exemple, *Homme* ou *Femme*).
- **annee** : Année au cours de laquelle les informations salariales ont été collectées.
- **t** : Indice temporel représentant le point d'observation longitudinal.
- **y** : Salaire annuel brut déclaré par l'individu.

Cette structure permet une analyse longitudinale rigoureuse, facilitant l'estimation des effets du genre et du temps sur les évolutions salariales.

## 2. Analyse des variables d'intérêt

### Interprétations des Figures

#### Figure 2 - Boîtes à moustaches des salaires par année

On constate une augmentation générale des salaires au fil des années, indiquant une progression salariale moyenne dans la population étudiée.

#### Figure 3 - Moyennes des salaires par genre et par temps

Les salaires augmentent avec le temps, mais un écart constant entre les hommes et les femmes persiste, révélant une disparité salariale durable.




Figure 1: Évolution des salaires (lignes douces).




Figure 2: Boîtes à moustaches des salaires par année.




Figure 3: Moyennes des salaires par genre et par temps.

Figure 4: Comparaison graphique des salaires selon différentes analyses.

## Figure 1 - Évolution des salaires par individu

L'évolution des salaires par individu est très condensée, ce qui rend difficile une interprétation claire des trajectoires salariales individuelles.

### 3. Modélisation des évolutions salariales

Nous proposons trois types de modèles afin d'étudier l'évolution salariale des individus en fonction du temps écoulé depuis leur sortie du système éducatif et de leur genre. Les modèles suivants sont utilisés : un modèle linéaire simple, un modèle à effets mixtes, et un modèle à effets fixes.

#### Modèle Linéaire Simple

Le modèle linéaire simple que nous allons utiliser est une régression classique où le salaire de l'individu  $y_i$  est expliqué par une seule variable explicative, à savoir le genre  $Q_1$ , ce qui donne la forme suivante :

$$y_i = \beta_0 + \beta_1 \cdot Q_1 + \epsilon_i$$

**Explication :** Dans ce modèle,  $y_i$  représente le salaire de l'individu  $i$ .  $Q_1$  est une variable binaire indiquant le genre de l'individu (par exemple,  $Q_1 = 1$  pour les femmes et  $Q_1 = 0$  pour les hommes). Ce modèle cherche à capturer l'impact du genre sur le salaire, avec  $\beta_1$  comme coefficient qui représente la différence salariale entre les hommes et les femmes. L'erreur  $\epsilon_i$  capture la variabilité non expliquée par le modèle.

Ce modèle est relativement simple et permet de déterminer si, après avoir contrôlé le genre, il existe une différence significative entre les salaires des hommes et des femmes.

#### Modèle Linéaire Simple : Interprétation

- **Qualité du Modèle :**

- Le R-carré est de 0.0823, indiquant que 8.23% de la variance du salaire ( $y$ ) est expliquée par le genre ( $Q_1$ ).
- Le F-test ( $F = 28.87$ ,  $p < 0.0001$ ) montre que le genre a un effet global significatif sur les salaires.

- **Estimations et Tests :**

- L'intercept (1919.70) est le salaire moyen des femmes.
- Le coefficient pour les hommes (336.95,  $p < 0.0001$ ) indique que les hommes gagnent en moyenne 336.95 unités de salaire de plus que les femmes.

- **Interprétation dans le contexte de l'étude :**

- Malgré le même niveau d'éducation (Bac+5 ou plus), les hommes perçoivent un salaire significativement supérieur à celui des femmes.
- Cependant, le faible R-carré suggère que d'autres facteurs non inclus dans ce modèle expliquent une grande partie de la variance des salaires.

## Modèle à Effets Mixtes

Le modèle à effets mixtes tient compte à la fois des effets fixes et des effets aléatoires. Dans notre cas, nous introduisons les effets fixes pour le temps (année d'enquête) et le genre, et les effets aléatoires pour chaque individu, ce qui donne la forme suivante :

$$y_{it} = \beta_0 + \beta_1 \cdot \text{annee}_t + \beta_2 \cdot Q_{1i} + u_i + \epsilon_{it}$$

où : -  $y_{it}$  est le salaire de l'individu  $i$  à l'année  $t$ , -  $\beta_0$  est l'ordonnée à l'origine, -  $\beta_1$  est le coefficient pour l'année (l'effet fixe du temps), -  $\beta_2$  est le coefficient associé au genre  $Q_1$ , -  $u_i$  est l'effet aléatoire individuel (qui permet de capturer les variations non observées spécifiques à chaque individu), -  $\epsilon_{it}$  est l'erreur aléatoire.

**Explication :** Ce modèle permet d'analyser l'impact du temps (année d'enquête) et du genre sur l'évolution salariale, tout en tenant compte des effets non observés spécifiques à chaque individu. L'effet aléatoire  $u_i$  capture la variabilité individuelle qui n'est pas expliquée par les variables observées (le genre et le temps). L'ajout de ces effets aléatoires permet de mieux modéliser la structure longitudinale des données et de tenir compte des différences individuelles dans l'évolution salariale.

## Modèle à Effets Mixtes : Interprétation

- **Qualité du Modèle :**

- Les critères de qualité (AIC = 4731.7, BIC = 4758.0) indiquent un meilleur ajustement que le modèle linéaire simple.
- La matrice  $R$  montre une dépendance temporelle modérée à élevée entre les observations individuelles ( $R = 0.66$  entre  $t_3$  et  $t_4$ ).

- **Estimations et Tests :**

- L'intercept ( $-181455$ ) est une valeur de référence après prise en compte des effets aléatoires.
- Le coefficient pour *annee* (91.50,  $p < 0.0001$ ) montre une augmentation significative des salaires au fil des années.
- Le coefficient pour les hommes (320.10,  $p = 0.0007$ ) indique que, toutes choses égales par ailleurs, les hommes continuent de percevoir des salaires supérieurs.

- **Interprétation dans le contexte de l'étude :**

- L'ajout des effets aléatoires capture mieux les variations individuelles entre les sujets ( $i$ ).
- Cependant, une convergence imparfaite (hessien non défini positif) pourrait indiquer une difficulté à estimer précisément certains paramètres.

## Modèle à Effets Fixes

Le modèle à effets fixes est similaire au modèle à effets mixtes, mais ici, nous excluons les effets aléatoires. Nous modélisons le salaire en fonction du temps, du genre et de leur interaction :

$$y_i = \beta_0 + \beta_1 \cdot t_i + \beta_2 \cdot Q_{1i} + \beta_3 \cdot (t_i \cdot Q_{1i}) + \epsilon_i$$

où : -  $y_i$  est le salaire de l'individu  $i$ , -  $\beta_0$  est l'ordonnée à l'origine, -  $\beta_1$  est le coefficient pour le temps  $t$ , -  $\beta_2$  est le coefficient pour le genre  $Q_1$ , -  $\beta_3$  est le coefficient d'interaction entre le temps et le genre, -  $\epsilon_i$  est l'erreur aléatoire.

**Explication :** Ce modèle permet d'étudier l'impact du temps et du genre sur le salaire, tout en incluant une interaction entre ces deux variables. L'inclusion de l'interaction permet de tester si l'effet du temps sur le salaire varie en fonction du genre. Ce modèle suppose que chaque individu a un effet constant (sans effet aléatoire), et modélise la relation entre les variables indépendantes et le salaire à travers des effets fixes.

## Modèle à Effets Fixes : Interprétation

- **Qualité du Modèle :**

- Le modèle présente les meilleurs critères de qualité (AIC = 4699.4, BIC = 4723.4) parmi les trois.
- Les corrélations résiduelles ( $R$ ) entre les indices de temps sont élevées ( $R = 0.83$  entre  $t_3$  et  $t_4$ ), confirmant une forte dépendance longitudinale.

- **Estimations et Tests :**

- L'intercept (1590.69) est le salaire moyen des femmes au premier temps ( $t_1$ ).
- Les coefficients pour  $t_2, t_3, t_4$  montrent une augmentation significative des salaires au fil du temps ( $t_4$  ajoute 641.36 unités,  $p < 0.0001$ ).
- Le coefficient pour les hommes (319.59,  $p = 0.0009$ ) indique une différence significative avec les femmes.

- **Interprétation dans le contexte de l'étude :**

- Le modèle à effets fixes met en évidence des disparités salariales de genre persistantes, même après prise en compte des indices de temps.
- Il surpasse le modèle linéaire simple grâce à une meilleure prise en compte de la structure temporelle des données.

## Comparatif des Modèles

| Critères                        | Modèle Linéaire Simple                   | Modèle à Effets Mixtes               | Modèle à Effets Fixes                    |
|---------------------------------|------------------------------------------|--------------------------------------|------------------------------------------|
| Ajustement (AIC, BIC)           | N/A                                      | AIC = 4731.7, BIC = 4758.0           | AIC = 4699.4, BIC = 4723.4               |
| Effet du temps ( $t$ ) ou année | Non inclus                               | Inclus (91.50, $p < 0.0001$ )        | Inclus ( $t_4 = 641.36$ , $p < 0.0001$ ) |
| Effet du genre ( $Q_1$ )        | 336.95, $p < 0.0001$                     | 320.10, $p = 0.0007$                 | 319.59, $p = 0.0009$                     |
| Structure temporelle ( $R$ )    | Non modélisée                            | Modélisée (corrélations temporelles) | Modélisée                                |
| Avantages                       | Simple à interpréter                     | Capture les variations individuelles | Meilleur ajustement global               |
| Inconvénients                   | Ne modélise pas la dépendance temporelle | Convergence parfois instable         | Ne capture pas les effets individuels    |

Table 1: Comparatif des modèles : Synthèse des performances et caractéristiques.

## Récapitulatif de l'analyse des modèles

Le modèle à **effets fixes** se révèle être le choix optimal pour cette analyse. Il offre les meilleurs critères d'ajustement ( $AIC = 4699.4$ ,  $BIC = 4723.4$ ) et permet de modéliser explicitement l'évolution temporelle ( $t$ ) ainsi que l'impact du genre ( $Q1$ ).

Cependant, si les variations interindividuelles nécessitent une attention particulière, le modèle à **effets mixtes** pourrait être envisagé, bien qu'il présente des défis en termes de convergence.

Le modèle linéaire simple est utile pour une exploration préliminaire, mais il est limité car il ne tient pas compte de la structure longitudinale des données. Par conséquent, il est moins adapté pour répondre pleinement à la problématique d'évolution salariale dans le temps.

## 4. Conclusion

Cette étude analyse l'impact du genre sur l'évolution salariale des individus ayant un niveau d'éducation Bac+5 ou plus, résidant en Île-de-France, en utilisant les données de l'enquête "Génération 1998 à 10 ans". L'objectif principal était d'examiner si des différences salariales persistent entre hommes et femmes au fil du temps, malgré un niveau de qualification équivalent.

Les résultats montrent que le **genre** a un impact significatif sur l'évolution salariale. En effet, les hommes bénéficient d'une progression salariale plus importante que celle des femmes, validant ainsi l'hypothèse que, malgré une qualification équivalente, les femmes subissent une progression salariale inférieure. Cette différence salariale est significative, avec un coefficient estimé pour le genre masculin ( $p < 0.0001$ ) indiquant un effet positif.

## Limites de l'étude

Plusieurs limites doivent être prises en compte :

- **Données géographiquement restreintes** : L'échantillon se limite à l'Île-de-France, ce qui empêche la généralisation des résultats à l'ensemble du territoire.
- **Variables contextuelles non incluses** : D'autres facteurs comme l'expérience professionnelle, le secteur d'activité, ou la situation familiale des individus n'ont pas été intégrés.
- **Modèles simplifiés** : Les modèles utilisés ne tiennent pas compte de la complexité des interactions entre variables contextuelles, ce qui pourrait affiner les résultats.

En résumé, bien que l'étude valide l'existence d'une inégalité salariale entre hommes et femmes dans le cadre des diplômés Bac+5, il reste nécessaire de compléter cette analyse en tenant compte de variables supplémentaires et de méthodes statistiques plus avancées. Ces ajustements permettront de mieux comprendre les causes de ces disparités et d'élargir les conclusions à d'autres populations.

## Bibliographie

Foliano, F., Bryson, A., Joshi, H., Wielgoszewska, B., & Wilkinson, D. (2023). *Gender Wage Gap among Young Adults: A Comparison across British Cohorts*. Prépublication en ligne.

Meurs, D., & Ponthieux, S. (2006). *L'écart des salaires entre les femmes et les hommes peut-il encore baisser?*. Économie et Statistique. <https://doi.org/10.3406/estat.2006.7119>