

# Rapport de projet DM de Statistique spatiale

## Analyse Spatiale de la Pauvreté Infantile du sud/sud-est des Etats-Unis

Master 2 Mathématiques Appliquées et Sciences Sociales,  
Analyse de population



### Auteurs:

**Arezki HASSAK**  
**GRONDIN Mathieu**  
**SIDIBÉ Ablaye Sow**

### Enseignante:

**Laurence REBOUL**

# TD3\_DM : Statistiques Spatiales

2025-03-08

## Table of Contents

|                                                                                                |    |
|------------------------------------------------------------------------------------------------|----|
| Introduction.....                                                                              | 3  |
| Environnement de travail et les bibliothèques nécessaires .....                                | 3  |
| Chargement des packages .....                                                                  | 3  |
| Partie 1 : Etude de l'autocorrélation spatiale de la pauvreté infantile .....                  | 3  |
| 1) .....                                                                                       | 3  |
| Chargement des données .....                                                                   | 3  |
| Création du voisinage de type Queen et de la matrice de poids .....                            | 3  |
| 2) Cartographie de la Pauvreté Infantile (PPOV) .....                                          | 4  |
| Test de Moran pour l'Autocorrélation Spatiale Globale .....                                    | 5  |
| 4) Test d'association spatiale locale .....                                                    | 8  |
| Partie 2 : Modélisation de la pauvreté.....                                                    | 12 |
| Modélisation aspatiale : .....                                                                 | 12 |
| 5) Visualiser la matrice de corrélation avec un graphique .....                                | 12 |
| 6) Mettre en œuvre le modèle sous R.....                                                       | 14 |
| 7) En quoi le résultat obtenu pour la variable PBLK dans la régression est incohérent ?.       | 15 |
| 8) Etude de la multicolinéarité des variables explicatives .....                               | 15 |
| Question 9 .....                                                                               | 16 |
| Modélisations spatiales : .....                                                                | 21 |
| 10) Choix entre le modèle LAG et le modèle SEM.....                                            | 21 |
| 11) Mise en oeuvre du modèle SEM .....                                                         | 22 |
| 12) Mise en oeuvre du modèle non choisi.....                                                   | 24 |
| 13) Mise en oeuvre du test d'hétéroscédasticité du modèle SEM.....                             | 26 |
| Règle de décision : .....                                                                      | 26 |
| 14) Mise en oeuvre du modèle SDM.....                                                          | 26 |
| 15) Implémentation du modèle SDM.....                                                          | 27 |
| 16) Comparaison du modèle SDM et SEM.....                                                      | 28 |
| 17) Interprétation des effets des covariables sur PPOV et étude des différences avec SEM ..... | 28 |
| 18) D'après les sorties du modèle SDM .....                                                    | 30 |

## Introduction

Ce devoir vise à analyser la pauvreté infantile dans le sud et le sud-est des États-Unis en utilisant des méthodes de statistiques spatiales sous R.

Nous allons examiner :

- L'autocorrélation spatiale de la proportion d'enfants en situation de pauvreté
- L'impact des facteurs socio-économiques à travers des modèles de régression linéaire et spatiale.

## Environnement de travail et les bibliothèques nécessaires

### Chargement des packages

## Partie 1 : Etude de l'autocorrélation spatiale de la pauvreté infantile

1)

### Chargement des données

```
south00_shp<-st_read("south00.shp")

## Reading layer `south00' from data source
##   `C:\Users\MASS\Desktop\M2 MASS POP\S2\Statistiques
##   Spatiale\TD\TD3\south00.shp'
##   using driver `ESRI Shapefile'
## Simple feature collection with 1387 features and 17 fields
## Geometry type: MULTIPOLYGON
## Dimension:      XY
## Bounding box:   xmin: -957551.2 ymin: -1609326 xmax: 1747589 ymax: 175426.2
## CRS:            NA

south00_dbf <- st_read("south00.dbf")

## Reading layer `south00' from data source
##   `C:\Users\MASS\Desktop\M2 MASS POP\S2\Statistiques
##   Spatiale\TD\TD3\south00.dbf'
##   using driver `ESRI Shapefile'
## Simple feature collection with 1387 features and 17 fields
## Geometry type: MULTIPOLYGON
## Dimension:      XY
## Bounding box:   xmin: -957551.2 ymin: -1609326 xmax: 1747589 ymax: 175426.2
## CRS:            NA
```

### Création du voisinage de type Queen et de la matrice de poids

```
neighbors <- poly2nb(south00_dbf, queen = TRUE) # Création d'un objet de
voisinage basé sur la contiguïté des polygones (comtés voisins)
```

```
weights <- nb2listw(neighbors, style = "W", zero.policy = TRUE) # Créer La  
matrice de poids spatiaux à
```

## 2) Cartographie de la Pauvreté Infantile (PPOV)

```
qtm(south00_shp, fill = "PPOV", fill.palette = "-RdBu", title = "Taux de  
pauvreté infantile")
```

```
##
```

```
## — tmap v3 code detected
```

---

```
## [v3->v4] `tm_qtm()`: migrate the argument(s) related to the scale of the  
visual
```

```
## variable `fill` namely 'palette' (rename to 'values') to fill.scale =  
## tm_scale(<HERE>).
```


```
## Multiple palettes called "rd_bu" found: "brewer.rd_bu",  
"matplotlib.rd_bu". The first one, "brewer.rd_bu", is returned.
```

```
##
```

```
## [cols4all] color palettes: use palettes from the R package cols4all. Run  
## `cols4all::c4a_gui()` to explore them. The old palette name "-RdBu" is  
named
```

```
## "rd_bu" (in long format "brewer.rd_bu")
```

### Taux de pauvreté infantile




Cette cartographie de la pauvreté infantile par comté dans le Sud/Sud-Est des Etats-Unis permet de visualiser les zones où la pauvreté infantile est élevée ou non. Plus précisément, nous voyons que les zones ayant une proportion de pauvreté infantile est plus élevée dans

l'extrême ouest, centre et une partie du Nord-Est. nous observons que les zones géographiques voisines ont tendance à présenter des taux de pauvreté similaires, ce qui témoigne d'une autocorrélation spatiale. Cette concentration de valeurs proches suggère que les dynamiques socio-économiques sont influencées par leur localisation.

### Test de Moran pour l'Autocorrélation Spatiale Globale

Le test de Moran permet de tester l'existence d'une autocorrélation spatiale entre les comtés. Pour ce faire nous vérifions tout d'abord si la part des enfants pauvres suit une distribution normale.

```
hist(south00_dbf$PPOV,  
     col = "skyblue",  
     border = "black",  
     main = "Distribution de la pauvreté infantile",  
     xlab = "Proportion d'enfants en pauvreté",  
     ylab = "Fréquence")
```



```
# Test de Shapiro-Wilk sur PPOV  
shapiro.test(south00_dbf$PPOV)  
  
##  
## Shapiro-Wilk normality test  
##  
## data: south00_dbf$PPOV  
## W = 0.97175, p-value = 7.651e-16
```

Le test de Shapiro-Wilk rejette l'hypothèse de normalité, indiquant que la distribution du vecteur d'observation ne suit pas une loi normale.

Ainsi, nous testons :

- H0 : absence d'autocorrélation spatiales globale (c'est-à-dire que la répartition de la pauvreté infantile est spatialement aléatoire).
- H1 : autocorrélation spatiales positive (c'est-à-dire que la répartition de la pauvreté infantile est non aléatoire et présente une structure spatiale).

```
# Utiliser la fonction moran.mc() pour tester l'autocorrélation spatiale
moran_result <- moran.mc(south00_dbf$PPOV, weights, nsim = 999)
moran_result

##
## Monte-Carlo simulation of Moran I
##
## data: south00_dbf$PPOV
## weights: weights
## number of simulations + 1: 1000
##
## statistic = 0.5893, observed rank = 1000, p-value = 0.001
## alternative hypothesis: greater

# Utiliser la fonction moran.test() pour tester l'autocorrélation spatiale
moran_test_result <- moran.test(south00_dbf$PPOV, weights)
# Afficher les résultats
moran_test_result

##
## Moran I test under randomisation
##
## data: south00_dbf$PPOV
## weights: weights
##
## Moran I statistic standard deviate = 36.544, p-value < 2.2e-16
## alternative hypothesis: greater
## sample estimates:
## Moran I statistic      Expectation      Variance
##      0.5892974827      -0.0007215007      0.0002606743
```

La fonction `moran.mc()` utilise la simulation pour obtenir l'indice de Moran et la p-valeur, ce qui peut être particulièrement utile lorsqu'il n'y a pas de distribution normale. Cela permet de tester l'autocorrélation dans des contextes plus complexes ou lorsque la distribution sous-jacente de l'indice de Moran n'est pas claire. Cependant, `moran.test()` est plus rapide et donne un test basé sur la distribution théorique de Moran's I, ce qui est valable lorsque l'on suppose que la distribution suit les hypothèses standards (notamment, que la distribution des valeurs de la variable suit un modèle de distribution normale).


La statistique de Moran I obtenue est 0.5893, indiquant une forte autocorrélation spatiale positive. Cela signifie que les zones présentant des niveaux similaires de pauvreté infantile sont géographiquement regroupées plutôt que réparties de manière aléatoire.

Nombre de simulations : 999 répétitions + 1 valeur observée = 1000 simulations Rang observé : 1000, ce qui signifie que toutes les valeurs simulées sont inférieures à la valeur observée de Moran I. p-value = 0.001 : Moins de 0.1% des valeurs simulées dépassent la valeur observée de Moran I.

Avec un risque de première espèce de 5%, on a p-valeur < 5% ce qui conduit à rejeter H0 et à choisir H1 : donc il existe une association spatiale positive.

```
# Histogramme des valeurs simulées de Moran's I sous H0 (bootstrap)
hist(moran_result$res[1:999],
     breaks = 20,                # Nombre de classes pour lisser l'histogramme
     freq = TRUE,                # Affichage en fréquence
     col = "lightblue",          # Couleur des barres
     border = "black",           # Bordures noires pour lisibilité
     main = "Répartition des valeurs de I simulées",
     xlab = "Simulated Moran's I",
     xlim = c(-0.04, 0.04),      # Restriction de l'axe X entre -0.04 et 0.04
     ylim = c(0, max(hist(moran_result$res[1:999], plot = FALSE)$counts) *
1.2)) # Ajustement Y
```


### Répartition des valeurs de I simulées



```
# Ajouter une ligne rouge pour la valeur observée de Moran
```

```
# QQ-plot restreint à l'intervalle [-0.04, 0.04]
qqnorm(moran_result$res,
      main = "Distribution des statistiques bootstrap sous H0",
      xlab = "Theoretical Quantiles",
      ylab = "Sample Quantiles",
      ylim = c(-0.04, 0.04)) # Limite de l'axe Y

# Ajouter la ligne de référence pour la normalité
qqline(moran_result$res, col = "red", lwd = 2)
```



La distribution des statistiques bootstrap semble gaussienne et l'hypothèse de randomisation semble vérifiée.

#### 4) Test d'association spatiale locale

```
local_moran <- localmoran(south00_dbf$PPOV, weights)
south00_dbf$LISA <- local_moran[,1]
```

Tout d'abord, nous avons calculé les indices locaux de Moran à l'aide de la fonction `localmoran()` ci-dessus.

Nous obtenons une nouvelle colonne LISA dans la table `south00_dbf` qui présente des valeurs d'autocorrélation spatiale locale.

- Lorsque la valeur de l'autocorrélation spatiale de la région est positive, cela veut dire que la région qui a une forte (resp faible) pauvreté est entourée de régions où la pauvreté est également élevée (resp faible).



```
# Création des catégories en fonction des résultats LISA
south00_dbf$liisa_cat <- factor(
  ifelse(south00_dbf$LISA > 0 & south00_dbf$pval_correc < 0.05, "HH", #
  High-High
```

```

    ifelse(south00_dbf$LISA < 0 & south00_dbf$pval_correc < 0.05, "LL",
# Low-Low
    ifelse(south00_dbf$LISA > 0 & south00_dbf$pval_correc >=
0.05, "LH", # Low-High (non-significatif)
    ifelse(south00_dbf$LISA < 0 & south00_dbf$pval_correc
>= 0.05, "HL", "Non-Significant")))) # High-Low (non-significatif)
# Convertir l'objet spatial (SpatialPolygonsDataFrame ou
SpatialPointsDataFrame) en sf
south00_sf <- st_as_sf(south00_dbf)


```

Nous effectuons une carte avec les caractéristiques LISA (HH, LL, LH, HL). Les tests LISA permettent de déterminer les zones locales d'autocorrélation spatiale. Ces 4 catégories se définissent de la manière suivante : - HH : Zones à forte pauvreté infantile, entourée de zones similaires. - LL : Zones à faible pauvreté infantile, entourée de zones similaires. - LH : Zones à faible pauvreté infantile, entourée de zones à forte pauvreté. - HL : Zones à forte pauvreté infantile, entourée de zones à faible pauvreté.

```

# Créer une carte en fonction des catégories LISA
ggplot(south00_sf) +
  geom_sf(aes(fill = lisa_cat), color = "black", lwd = 0.2) +
  scale_fill_manual(values = c("HH" = "red", "LL" = "green", "LH" = "blue",
"HL" = "yellow", "Non-Significant" = "grey")) +
  theme_minimal() +
  labs(title = "Carte des catégories LISA de la pauvreté infantile",
    fill = "Catégories LISA") +
  theme(legend.position = "right")

```




```
# Différencier les zones significatives et non-significatives
south00_dbf$lisa_signif <- ifelse(south00_dbf$pval_correc < 0.05,
"Significative", "Non-Significative")
```

Nous avons refait la même carte, mais en différenciant les slots non-significatifs (d'après les LISA) des autres.

```
# Si south00_dbf n'est pas encore un objet sf, vous pouvez le convertir en sf
library(sf)
south00_sf <- st_as_sf(south00_dbf)

# Créer la carte avec ggplot2
ggplot(south00_sf) +
  geom_sf(aes(fill = lisa_signif), color = "black", lwd = 0.2) +
  scale_fill_manual(values = c("Significative" = "blue", "Non-Significative"
= "grey")) +
  theme_minimal() +
  labs(title = "Carte des zones significatives vs non-significatives",
fill = "Signification") +
  theme(legend.position = "right")
```



```
south00_sf <- st_drop_geometry(south00_sf)
```

D'après ce graphique,

les zones coloriées en bleu, indiquent les régions où l'autocorrélation spatiale de la pauvreté infantile est élevée, ce qui signifie que ces zones ont des caractéristiques similaires en termes de proportion d'enfants vivant dans la pauvreté.

les zones coloriées en gris, indiquent les comtés où l'autocorrélation spatiale de la pauvreté infantile n'est pas vérifiée statistiquement, ce qui signifie que la pauvreté infantile dans ces zones n'est pas fortement influencée par des facteurs géographiques voisins.

De plus, nous pouvons observer que les zones significatives sont regroupées géographiquement et que les non-significatives sont dispersées donc l'autocorrélation spatiale est plus homogène dans certaines régions, mais qu'elle est variable dans d'autres. Nous pouvons conclure que l'autocorrélation spatiale de la pauvreté infantile n'est pas homogène sur l'ensemble du territoire.

Nous observons globalement une relation linéaire positive entre le taux de pauvreté d'une zone et celui de son voisinage, ce qui confirme les résultats des tests globaux précédents. Cette corrélation est relativement forte, comme en témoigne le faible nombre d'observations dans les quadrants LH (faible pauvreté entourée de forte pauvreté) et HL (forte pauvreté entourée de faible pauvreté).

## Partie 2 : Modélisation de la pauvreté

### Modélisation spatiale :


#### 5) Visualiser la matrice de corrélation avec un graphique

```
# Sélection des variables explicatives et de la variable à expliquer (PPOV)
variables_explicatives <- south00_sf[,
c("PHSP", "PFHH", "PUNEM", "PEXTR", "PBLK", "P65UP", "METRO", "PHSPLUS")]

# Ajout la variable à expliquer PPOV
variables_tot <- cbind(PPOV = south00_dbf$PPOV, variables_explicatives)

# Calcul de la matrice de corrélation
correlation_matrice <- cor(variables_tot, use = "complete.obs")

corrplot(correlation_matrice, type="upper", sig.level = 0.05,
method="number", number.cex=0.5)
```



D'après la matrice des corrélations ci-dessus, nous constatons que les variables PHSPLUS (Logarithme de la proportion de diplômés du secondaire ou plus.) et PPOV (Proportion d'enfants vivant dans la pauvreté) présentent une corrélation de -0,53 donc dans les régions où la proportion d'enfants vivant dans la pauvreté est élevée, la proportion de personnes diplômées du secondaire ou plus est faible, et inversement, dans les régions où la pauvreté infantile est faible, la proportion de diplômées du secondaire ou plus est élevée.

Nous constatons que les variables METRO (Comté métropolitain) et PPOV (Proportion d'enfants vivant dans la pauvreté) présentent une corrélation de -0,42 donc cette relation n'est pas extrêmement forte et que les comtés métropolitains tendent à avoir des taux de pauvreté infantile plus faibles que les comtés non-métropolitains.

Nous observons que les variables PFHH (Proportion de femmes chef de famille) et PPOV (Proportion d'enfants vivant dans la pauvreté) présentent une corrélation de 0,56 donc cette relation est plutôt modérée à forte et dans les régions où la proportion de femmes chef de famille est plus élevée, la proportion d'enfants vivant dans la pauvreté a tendance à être plus élevée aussi.

Nous voyons que les variables PBLK (Proportion d'afro-américains) et PPOV (Proportion d'enfants vivant dans la pauvreté) présentent une corrélation de 0,41 donc cette relation est modérée et dans les régions où la proportion d'afro-américains est plus élevée, la proportion d'enfants vivant dans la pauvreté tend également à être plus élevée.

## 6) Mettre en œuvre le modèle sous R

```
# Conversion de la variable METRO en facteur
south00_sf$METRO <- as.factor(south00_sf$METRO)
levels(south00_sf$METRO)

## [1] "0" "1"

# Mettre la modalité "0" de la variable METRO comme modalité de référence du
# modèle
south00_sf$METRO <- relevel(south00_sf$METRO, ref = "0")

# Création du modèle de régression linéaire multiple
model_reg <- lm(PPOV ~ PFHH + PBLK + PHSPLUS + PEXTR + PUNEM + METRO + PHSP +
P65UP, data = south00_sf)
summary(model_reg)

##
## Call:
## lm(formula = PPOV ~ PFHH + PBLK + PHSPLUS + PEXTR + PUNEM + METRO +
##     PHSP + P65UP, data = south00_sf)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.194206 -0.025234 -0.001538  0.023895  0.246325
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.053335   0.009651   5.527 3.90e-08 ***
## PFHH         0.748316   0.038598  19.387 < 2e-16 ***
## PBLK        -0.110581   0.014623  -7.562 7.21e-14 ***
## PHSPLUS     -0.243284   0.012841 -18.946 < 2e-16 ***
## PEXTR        0.391433   0.024612  15.904 < 2e-16 ***
## PUNEM        1.408049   0.059929  23.495 < 2e-16 ***
## METRO1      -0.007764   0.002998  -2.590  0.0097 **
## PHSP         0.048178   0.009625   5.005 6.30e-07 ***
## P65UP        0.030057   0.035549   0.846  0.3980
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.04261 on 1378 degrees of freedom
## Multiple R-squared:  0.7832, Adjusted R-squared:  0.7819
## F-statistic: 622.3 on 8 and 1378 DF, p-value: < 2.2e-16
```

En regardant le modèle de régression multiple, nous constatons que les p-valeurs des covariables du modèle sont toutes inférieures à 5% donc elles sont toutes significatives, hormis la covariable P65UP qui a une p-valeur égale à 0,3980 > 5% donc elle n'est pas significative.

Concernant l'estimation de la covariable PFHH qui vaut 0.748316, cela veut dire que chaque augmentation d'un point de la proportion de femmes chef de famille est associée à une augmentation de 0,75% de la proportion de la pauvreté infantile.

Concernant l'estimation de la covariable PBLK qui vaut -0.110581, cela veut dire que chaque augmentation d'un point de la proportion d'afro-américains est associée à une diminution de 0,11% de la proportion de la pauvreté infantile.

Concernant l'estimation de la covariable PHSPLUS qui vaut -0.243284, cela veut dire que chaque augmentation d'un point du logarithme de la proportion de diplômés du secondaire ou plus est associée à une diminution de 0,24% de la proportion de la pauvreté infantile.

Concernant l'estimation de la covariable PEXTR qui vaut 0,391433, cela veut dire que chaque augmentation d'un point de la proportion d'employés dans l'industrie extractive est associée à une augmentation de 0,39% de la proportion de la pauvreté infantile.

Concernant l'estimation de la covariable PUNEM qui vaut 1,408049, cela veut dire que chaque augmentation d'un point de la proportion de sans emploi est associée à une augmentation de 1,41% de la proportion de la pauvreté infantile.

Concernant l'estimation de la covariable METRO qui vaut -0,007764, cela veut dire que les comtés métropolitains ont, en moyenne, une réduction de 0,008 point de pourcentage de la proportion de la pauvreté infantile par rapport aux comtés non-métropolitains.

Concernant l'estimation de la covariable PHSP qui vaut 0,048178, cela veut dire que chaque augmentation d'un point de la proportion d'hispaniques est associée à une augmentation de 0,05% de la proportion de la pauvreté infantile.

Cependant, la covariable P65UP n'est pas significative dans le modèle, ce qui signifie qu'elle n'a pas d'impact statistique sur la proportion de la pauvreté infantile.

## 7) En quoi le résultat obtenu pour la variable PBLK dans la régression est incohérent ?

Dans la question 5), nous avons constaté que, en interprétant les corrélations, dans les régions où la proportion d'afro-américains est plus élevée, la proportion d'enfants vivant dans la pauvreté tend également à être plus élevée, tandis que, dans la question 6), nous avons constaté, en interprétant les estimations du modèle, que chaque augmentation d'un point de la proportion d'afro-américains est associée à une diminution de 0,11% de la proportion de la pauvreté infantile, ce qui est incohérent.

## 8) Etude de la multicolinéarité des variables explicatives

```
# Charger le package car  
library(car)
```

```
# Ajuster le modèle de régression multiple  
modele_ajuste <- lm(PPOV ~ PFHH + PBLK + PHSPLUS + PEXTR + PUNEM + METRO +  
PHSP + P65UP, data = south00_sf)
```

```
# Calcul des VIF
vif_val <- vif(modele_ajuste)

# Afficher les résultats
print(vif_val)

##      PFHH      PBLK  PHSPLUS  PEXTR  PUNEM  METRO  PHSP  P65UP
## 5.867381 5.224766 1.368849 1.699723 1.710764 1.615034 1.413508 1.393145
```

Nous avons calculé la VIF pour chaque variable explicative en utilisant la fonction `vif()`, pour ajuster le modèle de régression multiple. Nous obtenons, pour la covariable PBLK, une valeur VIF de 5,224766 > 4 donc cela indique qu'elle est fortement corrélée à une ou plusieurs autres variables du modèle. Cette covariable possède une grande variance et nous pouvons en déduire que la multicolinéarité est un problème et c'est pour cela que nous retrouvons des résultats incohérents entre les corrélations et les estimations du modèle de régression linéaire.

## Question 9


```
# Ajuster le modèle sans PBLK
modele_sans_PBLK <- lm(PPOV ~ PHSP + PFHH + PUNEM + PEXTR + PHSPLUS + METRO +
P65UP, data = south00_sf)

# Résumé du modèle
summary(modele_sans_PBLK)


##
## Call:
## lm(formula = PPOV ~ PHSP + PFHH + PUNEM + PEXTR + PHSPLUS + METRO +
##      P65UP, data = south00_sf)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.205612 -0.024960 -0.001279  0.024781  0.262327
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.075849   0.009365   8.099 1.21e-15 ***
## PHSP         0.067341   0.009473   7.109 1.87e-12 ***
## PFHH         0.497657   0.020175  24.667 < 2e-16 ***
## PUNEM        1.465323   0.060647  24.162 < 2e-16 ***
## PEXTR         0.343934   0.024277  14.167 < 2e-16 ***
## PHSPLUS      -0.243540   0.013100 -18.591 < 2e-16 ***
## METRO1       -0.008858   0.003054  -2.900 0.003792 **
## P65UP         0.119585   0.034195   3.497 0.000485 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.04347 on 1379 degrees of freedom
## Multiple R-squared:  0.7742, Adjusted R-squared:  0.7731
## F-statistic: 675.5 on 7 and 1379 DF, p-value: < 2.2e-16
```




```
# Graphiques de diagnostic du modèle
plot(modele_sans_PBLK)
```




$\text{POV} \sim \text{PHSP} + \text{PFHH} + \text{PUNEM} + \text{PEXTR} + \text{PHSPLUS} + \text{METRO} +$



$\text{POV} \sim \text{PHSP} + \text{PFHH} + \text{PUNEM} + \text{PEXTR} + \text{PHSPLUS} + \text{METRO} +$



POV ~ PHSP + PFHH + PUNEM + PEXTR + PHSPLUS + METRO +



POV ~ PHSP + PFHH + PUNEM + PEXTR + PHSPLUS + METRO +

```
# Charger le package spdep
library(spdep)
```

```
# Convertir en spatial
```

```

south00_dbf <- as(south00_dbf, "Spatial")

# Créer une matrice de voisinage spatiale
matrice_voispa <- coordinates(south00_dbf)

listw <- nb2listw(knn2nb(knearneigh(matrice_voispa, k = 5)), style = "W")

# Test de Moran sur les résidus
lm.morantest(modele_sans_PBLK, listw)


##
## Global Moran I for regression residuals
##
## data:
## model: lm(formula = PPOV ~ PHSP + PFHH + PUNEM + PEXTR + PHSPLUS +
## METRO + P65UP, data = south00_sf)
## weights: listw
##
## Moran I statistic standard deviate = 19.29, p-value < 2.2e-16
## alternative hypothesis: greater
## sample estimates:
## Observed Moran I      Expectation      Variance
##      0.3119560705      -0.0030680302      0.0002666919

# Ajouter les résidus au dataset spatial
south00_dbf$residus <- residuals(modele_sans_PBLK)

# Convertir en format sf
library(sf)
south00_sf <- st_as_sf(south00_dbf)

# Cartographie des résidus
ggplot(south00_sf) +
  geom_sf(aes(fill = residus), color = "black") +
  scale_fill_gradient2(low = "blue", mid = "white", high = "red", midpoint =
0) +
  theme_minimal() +
  labs(title = "Carte des résidus du modèle",
       fill = "Résidus") +
  theme(legend.position = "right")

```



```
# Charger Le package nécessaire
library(lmtest)

# Effectuer Le test de Breusch-Pagan
bp_test<- bptest(modele_sans_PBLK)

# Afficher Le résultat
print(bp_test)

##
## studentized Breusch-Pagan test
##
## data:  modele_sans_PBLK
## BP = 123.52, df = 7, p-value < 2.2e-16

# Calcul de Moran's I sur Les résidus du modèle_sans_PBLK
residuals_sans_PBLK <- residuals(modele_sans_PBLK)
moran_test <- lm.morantest(modele_sans_PBLK, listw = weights) # weights =
matrice de poids spatiale

print(moran_test)

##
## Global Moran I for regression residuals
##
## data:
## model: lm(formula = PPOV ~ PHSP + PFHH + PUNEM + PEXTR + PHSPLUS +
```

```
## METRO + P65UP, data = south00_sf)
## weights: weights
##
## Moran I statistic standard deviate = 19.154, p-value < 2.2e-16
## alternative hypothesis: greater
## sample estimates:
## Observed Moran I      Expectation      Variance
##      0.3044980977      -0.0030597865      0.0002578173
```

## Modélisations spatiales :

### 10) Choix entre le modèle LAG et le modèle SEM

Nous devons choisir le modèle LAG ou SEM en utilisant la fonction `lm.RStests` vu que la fonction `lm.LMtests` n'existe plus dans le package `spdep`.

```
# Ajuster le modèle de régression linéaire simple
lm_model_simple <- lm(PPOV ~ PFHH + PBLK + PHSPLUS + PEXTR + PUNEM + METRO +
PHSP + P65UP, data = south00_sf)
# Effectuer les tests LM pour choisir entre LAG et SEM
lm_tests <- lm.RStests(lm_model_simple, listw = listw, test = c("RSerr",
"RSlag", "RSerr", "RSlag"))

# Afficher les résultats
summary(lm_tests)

## Rao's score (a.k.a Lagrange multiplier) diagnostics for spatial
## dependence
## data:
## model: lm(formula = PPOV ~ PFHH + PBLK + PHSPLUS + PEXTR + PUNEM +
## METRO + PHSP + P65UP, data = south00_sf)
## test weights: listw
##
##      statistic parameter    p.value
## RSerr      301.89          1 < 2.2e-16 ***
## RSlag      286.81          1 < 2.2e-16 ***
## RSerr.1    301.89          1 < 2.2e-16 ***
## RSlag.1    286.81          1 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Nous voyons que les coefficients `RSerr` et `RSlag` sont significatifs car leurs p-valeurs sont inférieures à 5% mais `RSerr` > `RSlag` en termes d'estimation, donc nous choisissons le modèle SEM.

## 11) Mise en oeuvre du modèle SEM

Nous avons mis en œuvre le modèle choisi qui est le modèle SEM qui va nous permettre de corriger l'autocorrélation spatiale des erreurs dans la régression linéaire multiple. Nous avons utilisé la fonction `errorsarlm()`.

```
# Chargement du package nécessaire
library(spatialreg)

## Warning: le package 'spatialreg' a été compilé avec la version R 4.4.2

## Le chargement a nécessité le package : Matrix

##
## Attachement du package : 'spatialreg'

## Les objets suivants sont masqués depuis 'package:spdep':
##
##   get.ClusterOption, get.coresOption, get.mcOption,
##   get.VerboseOption, get.ZeroPolicyOption, set.ClusterOption,
##   set.coresOption, set.mcOption, set.VerboseOption,
##   set.ZeroPolicyOption

# Création une matrice de voisinage
coords <- st_coordinates(south00_sf) # Extraction des coordonnées si l'objet
est de type sf

# Ajuster Le modèle SEM (Spatial Error Model)
modele_SEM <- errorsarlm(PPOV ~ PFHH + PUNEM + PEXTR + P65UP + METRO +
  PHSPPLUS + PHSP,
                        data = south00_sf, listw = listw)

# Afficher Les résultats du modèle SEM
summary(modele_SEM)

##
## Call:errorsarlm(formula = PPOV ~ PFHH + PUNEM + PEXTR + P65UP + METRO +
##   PHSPPLUS + PHSP, data = south00_sf, listw = listw)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.223053 -0.020450 -0.001184  0.020503  0.195970
##
## Type: error
## Coefficients: (asymptotic standard errors)
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  0.0706445  0.0103481   6.8268 8.681e-12
## PFHH         0.5997424  0.0222174  26.9942 < 2.2e-16
## PUNEM        0.9728737  0.0610115  15.9457 < 2.2e-16
## PEXTR        0.3101220  0.0264014  11.7464 < 2.2e-16
```

```
## P65UP      0.1290288  0.0374112  3.4489 0.0005628
## METRO      -0.0039671  0.0027383  -1.4488 0.1474069
## PHSPLUS    -0.2169196  0.0126456 -17.1537 < 2.2e-16
## PHSP       0.0896123  0.0145636  6.1531 7.596e-10
##
## Lambda: 0.62428, LR test value: 333.59, p-value: < 2.22e-16
## Asymptotic standard error: 0.027073
##      z-value: 23.059, p-value: < 2.22e-16
## Wald statistic: 531.72, p-value: < 2.22e-16
##
## Log likelihood: 2552.081 for error model
## ML residual variance (sigma squared): 0.0013531, (sigma: 0.036784)
## Number of observations: 1387
## Number of parameters estimated: 10
## AIC: -5084.2, (AIC for lm: -4752.6)

# Comparaison avec le modèle de régression multiple
modele_sans_PBLK <- lm(PPOV ~ PFHH + PUNEM + PEXTR + P65UP + METRO + PHSPLUS
+ PHSP, data = south00_sf)
summary(modele_sans_PBLK)

##
## Call:
## lm(formula = PPOV ~ PFHH + PUNEM + PEXTR + P65UP + METRO + PHSPLUS +
##      PHSP, data = south00_sf)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.205612 -0.024960 -0.001279  0.024781  0.262327
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.075849   0.009365   8.099 1.21e-15 ***
## PFHH         0.497657   0.020175  24.667 < 2e-16 ***
## PUNEM        1.465323   0.060647  24.162 < 2e-16 ***
## PEXTR        0.343934   0.024277  14.167 < 2e-16 ***
## P65UP        0.119585   0.034195   3.497 0.000485 ***
## METRO       -0.008858   0.003054  -2.900 0.003792 **
## PHSPLUS     -0.243540   0.013100 -18.591 < 2e-16 ***
## PHSP        0.067341   0.009473   7.109 1.87e-12 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.04347 on 1379 degrees of freedom
## Multiple R-squared:  0.7742, Adjusted R-squared:  0.7731
## F-statistic: 675.5 on 7 and 1379 DF, p-value: < 2.2e-16

# AIC de modele_sans_PBLK
AIC(modele_sans_PBLK)

## [1] -4752.575
```

Pour interpréter le modèle, nous regardons l'effet spatial  $\lambda$  où :

- Si  $\lambda$  est proche de 0, les erreurs du modèle ne sont pas vraiment spatialement corrélées.
- Si  $\lambda$  est positive et significatif, les erreurs du modèle sont spatialement corrélées.

Après diffusion des résultats de ce modèle, nous voyons que  $\lambda$  est significatif car la p-valeur est inférieure à 5% (2.22e-16).

De plus, nous avons le paramètre  $\lambda=0.62428$  dans le modèle SEM, qui mesure l'autocorrélation spatiale des erreurs. Cette valeur positive est relativement élevée et significative induit que les erreurs du modèle sont spatialement corrélées. Donc les comtés voisins ont des niveaux de pauvreté infantile à peu près identiques.

Ensuite, nous avons comparé l'effet des variables explicatives du modèle SEM avec les résultats trouvés pour la RLM.

Nous retrouvons à peu près les mêmes effets des variables explicatives sur la variable à expliquer PPOV hormis la variable PUNEM qui a une estimation un peu plus conséquente et qui se rapproche de l'estimation issue du modèle avec PBLK, où l'estimation de la covariable PUNEM vaut 1.465323, cela veut dire que chaque augmentation d'un point de la proportion de sans emploi est associée à une augmentation de 1,47% de la proportion de la pauvreté infantile. De plus, contrairement au modèle RLM, la covariable METRO n'est pas significative étant donné que sa p-valeur est supérieure à 5%.

Aussi, nous avons l'AIC du modèle RLM d'une valeur de -4752.575 et l'AIC du modèle SEM d'une valeur de -5084.2.

Donc AIC (Modèle SEM) < AIC (Modèle RLM) alors le modèle SEM est mieux adapté par rapport au modèle RLM.

## 12) Mise en oeuvre du modèle non choisi

Nous avons également fait tourner le modèle non choisi qui est le modèle LAG qui prend en compte la dépendance spatiale dans la variable à expliquer PPOV. Nous avons utilisé la fonction `lagsarlm()`.

```
# Ajustement du modèle LAG
modele_LAG <- lagsarlm(PPOV ~ PFHH + PUNEM + PEXTR + P65UP + METRO + PHSPPLUS
+ PHSP, data = south00_sf, listw = listw)

# Résumé du modèle
summary(modele_LAG)

##
## Call:lagsarlm(formula = PPOV ~ PFHH + PUNEM + PEXTR + P65UP + METRO +
##   PHSPPLUS + PHSP, data = south00_sf, listw = listw)
##
## Residuals:
##      Min      1Q    Median      3Q     Max
## -2.1925e-01 -2.2285e-02 -7.8396e-05  2.1958e-02  2.1872e-01
```



```
##
## Type: lag
## Coefficients: (asymptotic standard errors)
##           Estimate Std. Error  z value  Pr(>|z|)
## (Intercept)  0.0318336  0.0087224   3.6496 0.0002626
## PFHH         0.4307412  0.0195436  22.0400 < 2.2e-16
## PUNEM        1.0713481  0.0577894  18.5388 < 2.2e-16
## PEXTR        0.2422348  0.0227617  10.6422 < 2.2e-16
## P65UP        0.1370373  0.0307840   4.4516 8.524e-06
## METRO       -0.0059897  0.0027508  -2.1775 0.0294465
## PHSPPLUS    -0.2107275  0.0119930 -17.5708 < 2.2e-16
## PHSP        0.0633930  0.0085616   7.4043 1.319e-13
##
## Rho: 0.32813, LR test value: 255.08, p-value: < 2.22e-16
## Asymptotic standard error: 0.020155
##      z-value: 16.281, p-value: < 2.22e-16
## Wald statistic: 265.06, p-value: < 2.22e-16
##
## Log likelihood: 2512.828 for lag model
## ML residual variance (sigma squared): 0.0015306, (sigma: 0.039123)
## Number of observations: 1387
## Number of parameters estimated: 10
## AIC: -5005.7, (AIC for lm: -4752.6)
## LM test for residual autocorrelation
## test value: 47.982, p-value: 4.3026e-12

# Utilisation de la fonction anova()
anova(modele_SEM, modele_LAG, modele_sans_PBLK)

##           Model df      AIC logLik Test L.Ratio p-value
## modele_SEM      1 10 -5084.2 2552.1    1
## modele_LAG      2 10 -5005.7 2512.8    1
## modele_sans_PBLK  3  9 -4752.6 2385.3    2  255.08      0

# Utilisation de la fonction LR.sarlm
LR.Sarlm(modele_SEM, modele_sans_PBLK)

##
## Likelihood ratio for spatial linear models
##
## data:
## Likelihood ratio = 333.59, df = 1, p-value < 2.2e-16
## sample estimates:
##      Log likelihood of modele_SEM Log likelihood of modele_sans_PBLK
##      2552.081                      2385.288

LR.Sarlm(modele_LAG, modele_sans_PBLK)

##
## Likelihood ratio for spatial linear models
##
```

```
## data:
## Likelihood ratio = 255.08, df = 1, p-value < 2.2e-16
## sample estimates:
##      Log likelihood of modele_LAG Log likelihood of modele_sans_PBLK
##      2512.828                      2385.288
```

Ensuite, nous avons comparé les modèles SEM, LAG et RLM à l'aide des fonctions `anova()` et `LR.sarlm()`. En utilisant le critère AIC, nous avons : AIC (Modèle SEM) < AIC (Modèle LAG) < AIC (Modèle RLM) donc le modèle SEM est plus préférable. En utilisant le test du rapport de vraisemblance, la log-vraisemblance du modèle LAG est de 2512.8 alors que celle du modèle SEM est de 2552.1 et celle du modèle RLM est de 2385.3. Donc le modèle SEM est plus vraisemblable pour modéliser la pauvreté infantile.

### 13) Mise en oeuvre du test d'hétéroscédasticité du modèle SEM

Ensuite, nous effectuons le test d'hétéroscédasticité, en appliquant le test de Breusch-Pagan sur le modèle SEM, à l'aide de la fonction `bptest()` du package `lmtest`.

```
library(lmtest)

# Extraction des résidus du modèle SEM
residuals_SEM <- residuals(modele_SEM)

# Test de Breusch-Pagan sur Les résidus du modèle SEM
bptest(residuals_SEM ~ PFHH + PUNEM + PEXTR + P65UP + METRO + PHSPPLUS + PHSP,
data = south00_sf)

##
## studentized Breusch-Pagan test
##
## data: residuals_SEM ~ PFHH + PUNEM + PEXTR + P65UP + METRO + PHSPPLUS +
PHSP
## BP = 172.14, df = 7, p-value < 2.2e-16
```

Formulation des hypothèses :

(H0) : Les résidus sont homoscedastiques (H1) : Les résidus sont hétéroscédastiques

#### Règle de décision :

Nous obtenons une p-valeur du test inférieure à  $2.2e-16$  donc inférieure à 5% donc nous rejetons (H0) et nous avons des résidus hétéroscédastiques. Donc le modèle SEM ne paraît pas correctement adapté aux données étant donné, de base, que le modèle SEM est un modèle spatial et non un modèle de régression linéaire.

### 14) Mise en oeuvre du modèle SDM

Le modèle SDM est plus général que les modèles SEM et LAG car il prend en compte la dépendance spatiale dans la variable à expliquer PPOV, que fait le modèle LAG, et la dépendance spatiale des variables explicatives du modèle, que fait le modèle SEM.

## 15) Implémentation du modèle SDM

Nous avons mis en œuvre le modèle SDM en utilisant la fonction `lagsarlm()` avec l'option `type = "mixed"`.

```
# utilisation de la fonction lagsarlm pour ajuster un modèle SDM
modele_SDM <- lagsarlm(PPOV ~ PFHH + PUNEM + PEXTR + P65UP + METRO + PHSPLUS
+ PHSP, data = south00_sf, listw = weights, type = "mixed")

# Résumé du modèle
summary(modele_SDM)

##
## Call:lagsarlm(formula = PPOV ~ PFHH + PUNEM + PEXTR + P65UP + METRO +
##       PHSPLUS + PHSP, data = south00_sf, listw = weights, type = "mixed")
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.23936170 -0.01973886 -0.00076802  0.01833189  0.17428113
##
## Type: mixed
## Coefficients: (asymptotic standard errors)
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  0.0367957  0.0122529   3.0030 0.0026732
## PFHH         0.6047231  0.0226218  26.7319 < 2.2e-16
## PUNEM        0.8498939  0.0605702  14.0316 < 2.2e-16
## PEXTR        0.2882838  0.0276158  10.4391 < 2.2e-16
## P65UP        0.1189128  0.0401249   2.9636 0.0030410
## METRO       -0.0022143  0.0027139  -0.8159 0.4145487
## PHSPLUS     -0.2046735  0.0129416 -15.8152 < 2.2e-16
## PHSP        0.0893706  0.0216480   4.1283 3.654e-05
## lag.PFHH     -0.4431783  0.0328930 -13.4733 < 2.2e-16
## lag.PUNEM    0.2217863  0.1087181   2.0400 0.0413491
## lag.PEXTR    -0.1379620  0.0396387  -3.4805 0.0005005
## lag.P65UP    -0.0836930  0.0564869  -1.4816 0.1384375
## lag.METRO    -0.0148854  0.0052524  -2.8340 0.0045966
## lag.PHSPLUS  0.0971944  0.0226904   4.2835 1.840e-05
## lag.PHSP     -0.0674699  0.0232130  -2.9066 0.0036544
##
## Rho: 0.51861, LR test value: 238.82, p-value: < 2.22e-16
## Asymptotic standard error: 0.030981
##      z-value: 16.74, p-value: < 2.22e-16
## Wald statistic: 280.21, p-value: < 2.22e-16
##
## Log likelihood: 2612.412 for mixed model
## ML residual variance (sigma squared): 0.001279, (sigma: 0.035763)
## Number of observations: 1387
## Number of parameters estimated: 17
## AIC: -5190.8, (AIC for lm: -4954)
```

```
## LM test for residual autocorrelation
## test value: 30.461, p-value: 3.4063e-08
```

## 16) Comparaison du modèle SDM et SEM

Pour comparer le modèle SDM et SEM, nous avons utilisé la fonction `LR.sarlm()`. Cette fonction effectue le test de rapport de vraisemblance qui permet de comparer deux modèles emboîtés de type spatial. Le but de ce test est de savoir si le modèle SDM, qui prend en compte l'effet spatial des erreurs et des variables explicatives, apporte une amélioration significative par rapport au modèle SEM, qui prend uniquement en compte l'effet spatial des erreurs.

Formulation du test :

(H0) : L'ajout des interactions spatiales sur les variables explicatives dans le modèle SDM n'apporte pas d'amélioration significative pour expliquer les données, par rapport au modèle SEM.

(H1) : L'ajout des interactions spatiales sur les variables explicatives dans le modèle SDM apporte une amélioration significative pour expliquer les données, par rapport au modèle SEM.

```
# Charger Le package
library(spatialreg)
# Comparaison des deux modèles avec LR.Sarlm()
LR.Sarlm(modele_SEM, modele_SDM)

##
## Likelihood ratio for spatial linear models
##
## data:
## Likelihood ratio = -120.66, df = 7, p-value < 2.2e-16
## sample estimates:
## Log likelihood of modele_SEM Log likelihood of modele_SDM
##                2552.081                2612.412
```

Grâce à la sortie R, nous avons une p-valeur inférieure à 5%, donc nous rejetons (H0) donc le modèle SDM est plus pertinent pour expliquer les données que le modèle SEM. Nous pouvons en déduire que l'ajout d'une interaction exogène nous paraît justifiée.

## 17) Interprétation des effets des covariables sur PPOV et étude des différences avec SEM

```
# Utilisation de la fonction impact()
impacts_SDM<-impacts(modele_SDM, R=200, type = "estimate",listw=listw)
summary(impacts_SDM, zstats=TRUE, short=TRUE)

## Impact measures (mixed, exact):
##           Direct Indirect      Total
## PFHH      0.588585842 -0.25300547  0.33558037
## PUNEM      0.932416018  1.29380749  2.22622351
```

```

## PEXTR      0.289721730  0.02254480  0.31226653
## P65UP      0.116169700 -0.04300693  0.07316277
## METRO     -0.004211393 -0.03131035 -0.03552174
## PHSPLUS   -0.205788460 -0.01748019 -0.22326865
## PHSP       0.086739849 -0.04124520  0.04549465
## =====
## Simulation results ( variance matrix):
## =====
## Simulated standard errors
##           Direct   Indirect   Total
## PFHH      0.020681091 0.04905507 0.04975836
## PUNEM      0.058623085 0.16578823 0.17698974
## PEXTR      0.028738963 0.06274929 0.06123370
## P65UP      0.037253905 0.09179506 0.09828451
## METRO      0.002570058 0.01050340 0.01112645
## PHSPLUS    0.014151038 0.03848583 0.04119871
## PHSP       0.021512479 0.02574943 0.01889468
##
## Simulated z-values:
##           Direct   Indirect   Total
## PFHH      28.560520 -5.2925543  6.6528737
## PUNEM      15.942498  7.8008557 12.5876704
## PEXTR      10.028361  0.4226537  5.1397506
## P65UP       3.091145 -0.5307862  0.6759321
## METRO      -1.576688 -2.9635671 -3.1618077
## PHSPLUS   -14.595718 -0.5047403 -5.4848776
## PHSP        4.000711 -1.6345550  2.3274460
##
## Simulated p-values:
##           Direct   Indirect   Total
## PFHH      < 2.22e-16 1.2062e-07 2.8743e-11
## PUNEM      < 2.22e-16 6.2172e-15 < 2.22e-16
## PEXTR      < 2.22e-16 0.672548  2.7510e-07
## P65UP      0.0019939 0.595567  0.4990838
## METRO      0.1148673 0.003041  0.0015679
## PHSPLUS    < 2.22e-16 0.613741  4.1376e-08
## PHSP       6.3153e-05 0.102142  0.0199415

```

Nous avons interprété les effets des covariables sur PPOV et les éventuelles différences trouvées avec le modèle SEM en utilisant la fonction `impact()`. Nous calculons l'impact des variables explicatives sur la variable à expliquer PPOV dans le modèle spatial SDM en simulant les p-valeurs des tests de significativité des impacts par bootstrap. Nous analysons les impacts de deux manières : les impacts directs, qui mesurent les effets des covariables sur la variable à expliquer PPOV en considérant l'influence spatiale des voisins, et les impacts indirects, qui mesurent les effets des covariables sur la variable à expliquer PPOV sans considérer l'influence spatiale des voisins.

Concernant la covariable PFHH, une augmentation de la proportion de femmes chef de famille augmente la proportion de pauvreté infantile dans la localité, tandis que, dans les

localités voisines, une augmentation de la proportion de femmes chef de famille diminue la proportion de pauvreté infantile.

Concernant la covariable PUNEM, une augmentation de la proportion de sans emploi augmente la proportion de pauvreté infantile dans la localité ou dans les localités voisines. Concernant la covariable PEXTR, une augmentation de la proportion d'employés dans l'industrie extractive augmente la proportion de pauvreté infantile dans la localité ou dans les localités voisines.

Concernant la covariable P65UP, une augmentation de la proportion de personnes âgées de 65 ans et plus augmente la proportion de pauvreté infantile dans la localité, tandis que, dans les localités voisines, une augmentation de la proportion de personnes âgées de 65 ans et plus diminue la proportion de pauvreté infantile.

Concernant la covariable METRO, dans un comté métropolitain ou dans les comtés métropolitains, la proportion de la pauvreté infantile est plus faible que dans un comté non métropolitain ou les comtés voisins non métropolitains.

Concernant la covariable PHSP, une augmentation du logarithme de la proportion de diplômés du secondaire ou plus diminue la proportion de pauvreté infantile dans la localité ou dans les localités voisines.

Concernant la covariable PHSP, une augmentation de la proportion d'hispaniques augmente la proportion de pauvreté infantile dans la localité, tandis que, dans les localités voisines, une augmentation de la proportion d'hispaniques diminue la proportion de pauvreté infantile.

En comparant avec le modèle SEM qui étudie les effets directs de ces covariables sur la pauvreté infantile, nous retrouvons des effets à peu près similaires par rapport aux effets dans le modèle SDM. Cela peut indiquer que la dépendance spatiale des erreurs capturée par le modèle SEM est assez proche de la dépendance spatiale dans les covariables capturée par le modèle SDM.

## **18) D'après les sorties du modèle SDM**

D'après les sorties du modèle SDM, nous avons constaté que l'AIC du modèle SDM est de - 5190.8 donc nous avons  $AIC(\text{Modèle SDM}) < AIC(\text{Modèle SEM})$ .

De plus, le test du rapport de vraisemblance, la log-vraisemblance du modèle SDM est de 2612.412 qui est supérieure à la log-vraisemblance des autres modèles comme le modèle SEM.

Nous pouvons dire que le modèle SDM avec interaction endogène améliore de manière significative la qualité d'ajustement.

Nous pouvons en déduire qu'il était pertinent d'ajouter un terme d'interaction endogène et que le modèle SDM est suffisant pour capter toute l'autocorrélation spatiale contenue dans les données car il prend en compte la dépendance spatiale non seulement dans l'erreur, mais aussi dans les variables explicatives.