



Projet : Modèle Logistique sous R

Programmation R pour la modélisation de Données en SHS

Groupe_4

GRONDIN MATHIEU, SIDIBE ABLAYE SOW, HASSAK AREZKI



Table of Contents

1.Importation des données.....	3
2. Tri à plat des variables	4
2.1.Resumé de la base de données.....	4
2.2.Tri à plat des variables de deux modalités	5
Tri à plat de la variable y (sentiment de discrimination).....	5
Tri à plat de la variable speak_german (parle-t-il allemand)	6
Tri à plat de la variable sexe (sexe de l'enquêté)	7
Tri à plat de la variable ind_origine (d'origine syrienne)	8
Tri à plat de la variable integrationcourse (cours d'intégration).....	9
Tri à plat des variables à trois modalités.....	10
2.3. Tri à plat des variables de trois modalités.....	11
Tri à plat de la variable tmpsallemmand (temps avec des personnes allemandes).....	11
Tri à plat de la variable work (l'enquêté occupe-t-il un emploi ?).....	12
Tri à plat de la variable tmpsorigine (l'enquêté passe-t-il du temps avec des personnes ayant la même origine ?).....	13
Tri à plat de la variable age (Age de l'enquêté au jour de l'enquête).....	14
3. Tris croisés de la variable y avec chacune des autres variables.....	16
Tri croisé de la variable y avec work.....	16
Tri croisé de la variable y avec tmpsorigine.....	16
Tri croisé de la variable y avec tmpsallemmand	17
Tri croisé de la variable y avec speak_german	17
Tri croisé de la variable y avec exclu.....	18
Tri croisé de la variable y avec ind_origine	18
Tri croisé de la variable y avec integrationcourse	19
4.Réalisation de l'équivalent de la question 3 pour les deux variables y et age	19
5. Modélisation de y par les variables âge et sexe suivant un modèle logistique additif	20
6. Estimation du modèle précédent.....	20
7. Estimation de la probabilité p (sentiment d'avoir été discriminé au moins une fois)	21
8.Construction d'un vecteur contenant les valeurs prédites	22
9. Le tableau de contingence croisant les valeurs observées et les valeurs prédites	22
10.Calcul des différentes quantités.....	22
11.Validation croisée.....	23
Définir à partir du data.frame asile_4 deux data frames.....	23

Estimation du modèle logistique à partir de asile_app	24
estimation du taux de mauvais classement sur la table asile_val.....	24
12. Constuction de la courbe ROC.....	25
13. Ajout d'une des variables inutilisées dans le modèle initial.....	27
13.1 Ajout de la variable Work.....	27
13.2 Ajout de la variable ind_origine.....	28
13.3 Ajout de la variable speak_german	30

1.Importation des données

```
asile_4 <- read.table("C:/Users/MASS/Documents/Modèle logistique sous R/jeu
de données-20240326/asile_4.txt", header = TRUE, sep=";")
```

```
asile_4$ident <- as.factor(asile_4$ident)
asile_4$y <- as.factor(asile_4$y)
asile_4$work <- as.factor(asile_4$work)
asile_4$tmpsorigine <- as.factor(asile_4$tmpsorigine)
asile_4$tmpsallemand <- as.factor(asile_4$tmpsallemand)
asile_4$speak_german <- as.factor(asile_4$speak_german)
asile_4$exclu <- as.factor(asile_4$exclu)
asile_4$sexe <- as.factor(asile_4$sexe)
asile_4$ind_origine <- as.factor(asile_4$ind_origine)
asile_4$integrationcourse <- as.factor(asile_4$integrationcourse)
asile_4$age <- as.numeric(asile_4$age)
```

```
levels(asile_4$y)
```

```
## [1] "0" "1"
```

```
levels(asile_4$y)<-c("non", "oui")
```

```
levels(asile_4$work)
```

```
## [1] "1" "3" "11"
```

```
levels(asile_4$work)<-c("non", "non éligible", "oui" )
```

```
levels(asile_4$tmpsorigine)
```

```
## [1] "1" "2" "6"
```

```
levels(asile_4$tmpsorigine)<-c("fréquemment", "occasionnellement", "jamais" )
```

```
levels(asile_4$tmpsallemand)
```

```
## [1] "1" "2" "6"
```

```

levels(asile_4$tmptsallemand)<-c("fréquentment","occasionnellement","jamais" )

levels(asile_4$speak_german)
## [1] "1" "2"

levels(asile_4$speak_german)<-c("oui","non")

levels(asile_4$exclu)
## [1] "1" "2" "5"

levels(asile_4$exclu)<-c("fréquentment","occasionnellement","jamais")

#levels(asile_4$sexe)
#levels(asile_4$sexe)<-c("homme"," femme")

levels(asile_4$ind_origine)
## [1] "1" "2"

levels(asile_4$ind_origine)<-c("oui","non")

levels(asile_4$integrationcourse)
## [1] "1" "2"

levels(asile_4$integrationcourse)<-c("oui","non")

```

2. Tri à plat des variables

2.1.Resumé de la base de données

```

summary(asile_4)
##      ident      y      work      tmptorigine
##  3      :   1  non:1286  non      :1712  fréquemment      :1183
##  4      :   1  oui: 714  non éligible: 82  occasionnellement: 495
##  6      :   1      oui      : 206  jamais           : 322
##  8      :   1
##  9      :   1
## 11      :   1
## (Other):1994
##      tmptsallemand  speak_german      exclu      sexe
##  fréquemment      :1147  oui:1014      fréquemment      :417  1:1231
##  occasionnellement: 468  non: 986      occasionnellement:949  2: 769
##  jamais           : 385      jamais           :634
##

```

```
##
##
##
## ind_origine integrationcourse      age
## oui:1024      oui: 693             Min.   :18.00
## non: 976      non:1307             1st Qu.:26.00
##                                         Median :32.00
##                                         Mean   :33.55
##                                         3rd Qu.:40.00
##                                         Max.   :76.00
##
```

2.2.Tri à plat des variables de deux modalités

Tri à plat de la variable y (sentiment de discrimination)


```
# Charger la librairie ggplot2
library(ggplot2)

## Warning: le package 'ggplot2' a été compilé avec la version R 4.3.3

# Calculer Les pourcentages
counts_y <- table(asile_4$y)
percentage_y <- prop.table(counts_y) * 100

# Créer Le barplot
p <- ggplot(data.frame(y = names(counts_y), count = as.vector(counts_y)),
aes(x = y, y = count, fill = y)) +
  geom_bar(stat = "identity") +
  labs(x = "Catégorie", y = "Fréquence", title = " Le sentiment d'avoir déjà
été discriminé au moins une fois") +
  theme_minimal()

# Ajouter Les pourcentages
p + geom_text(aes(label = paste0(round(percentage_y, 1), "%")), vjust = -0.5)
```




D'après le graphique, il y a une proportion plus importante de personnes qui ont le sentiment de n'avoir jamais été discriminé au moins une fois soit 64,3% tandis qu'il y a seulement 35,7 % des personnes qui ont le sentiment d'avoir été discriminé au moins une fois.

Tri à plat de la variable `speak_german` (parle-t-il allemand)

```
# Calculer les pourcentages
counts_speak_german <- table(asile_4$speak_german)
percentage_speak_german <- prop.table(counts_speak_german) * 100

# Créer le barplot
p <- ggplot(data.frame(speak_german = names(counts_speak_german), count =
as.vector(counts_speak_german)), aes(x = speak_german, y = count, fill =
speak_german)) +
  geom_bar(stat = "identity") +
  labs(x = "Parle allemand", y = "Fréquence", title = "Distribution de
l'enquête parle-t-il allemand ?") +
  theme_minimal()

# Ajouter les pourcentages
p + geom_text(aes(label = paste0(round(percentge_speak_german, 1), "%")),
vjust = -0.5)
```




D'après ce graphique, il y a une proportion quasi similaire de personnes qui parlent allemand (50,7%) que de personnes qui ne parlent pas allemand (49,3%)

Tri à plat de la variable sexe (sexe de l'enquête)

```
# Calculer les pourcentages
counts_sexe <- table(asile_4$sexe)
percentage_sexe <- prop.table(counts_sexe) * 100

# Créer le barplot
p_sexe <- ggplot(data.frame(sexe = names(counts_sexe), count =
as.vector(counts_sexe)), aes(x = sexe, y = count, fill = sexe)) +
  geom_bar(stat = "identity") +
  labs(x = "Sexe", y = "Fréquence", title = "Distribution du sexe des
enquêtés") +
  theme_minimal()

# Ajouter les pourcentages
p_sexe + geom_text(aes(label = paste0(round(percentages_sexe, 1), "%")), vjust
= -0.5)
```


D'après ce graphique, il y a une proportion légèrement plus importante de personnes qui sont d'origine syrienne soit 51,2% tandis que 48,8% de personnes ne sont pas d'origine syrienne.

Tri à plat de la variable `integrationcourse` (cours d'intégration)

```
# Calculer les pourcentages
counts_integrationcourse <- table(asile_4$integrationcourse)
percentage_integrationcourse <- prop.table(counts_integrationcourse) * 100

# Créer le barplot
p_integrationcourse <- ggplot(data.frame(integrationcourse =
names(counts_integrationcourse), count =
as.vector(counts_integrationcourse)), aes(x = integrationcourse, y = count,
fill = integrationcourse)) +
  geom_bar(stat = "identity") +
  labs(x = "Cours d'intégration", y = "Fréquence", title = "Distribution des
cours d'intégration") +
  theme_minimal()

# Ajouter les pourcentages
p_integrationcourse + geom_text(aes(label =
paste0(round(percentage_integrationcourse, 1), "%")), vjust = -0.5)
```



D'après ce graphique, il y a une proportion plus importante de personnes qui ont suivi des cours d'intégration soit 65,3% tandis que seulement 34,7% de personnes n'ont pas suivi de cours d'intégration.

Tri à plat des variables à trois modalités

```
# Fonction text_pie
text_pie <- function(vector, labels, cex=1) {
  vector <- vector/sum(vector)*2*pi
  temp <- c()
  j <- 0
  l <- 0
  for (i in 1:length(vector)) {
    k <- vector[i]/2
    j <- j+l+k
    l <- k
    text(cos(j)/2, sin(j)/2, labels[i], cex=cex)
  }
  vector <- temp
}
```

2.3. Tri à plat des variables de trois modalités


Tri à plat de la variable `tmpsallemand` (temps avec des personnes allemandes)

```
# Variable 'tmpsallemand'
counts_tmpsallemand <- table(asile_4$tmpsallemand)
labels_tmpsallemand <- c("Fréquemment", "Occasionnellement", "Jamais")
colors_tmpsallemand <- c("green", "red", "yellow")

# Calculer les pourcentages
total_tmpsallemand <- sum(counts_tmpsallemand)
pourcentages_tmpsallemand <- counts_tmpsallemand / total_tmpsallemand * 100

# Tracer le graphique en camembert

pie(counts_tmpsallemand, main="Temps passé avec des personnes allemandes",
    col=colors_tmpsallemand, labels =labels_tmpsallemand, sub = "Répartition de
la variable tmpsallemand" )
text_pie(pourcentages_tmpsallemand,
labels=paste0(round(pourcentages_tmpsallemand, 1), "%"), cex=1.1)
legend("bottomright", legend=labels_tmpsallemand, cex=0.7,
fill=colors_tmpsallemand, horiz=F)
```



D'après ce camembert, il y a une proportion majoritairement importante de personnes qui ont passé de manière assez fréquente avec des personnes allemandes soit 57,4%. Par opposition, il y a seulement 23,4% de personnes qui ont passé occasionnellement avec des personnes allemandes et 19,2% qui n'ont jamais passé du temps avec des personnes allemandes.


Tri à plat de la variable work (l'enquête occupe-t-il un emploi ?)

```
# Variable 'work'
counts_work <- table(asile_4$work)
labels_work <- c("Non", "Oui", "Non éligible")
colors_work <- c("green", "red", "yellow")

# Calculer les pourcentages
total_work <- sum(counts_work)
pourcentages_work <- counts_work / total_work * 100

# Tracer le graphique en camembert

pie(counts_work, col=colors_work, labels = labels_work, main="Occupation
professionnelle", sub="Répartition de variable 'work'")
text_pie(pourcentages_work, labels=paste0(round(pourcentages_work, 1), "%"),
cex=1.1)
legend("bottomleft", legend=labels_work, cex=0.7, fill=colors_work, horiz=F)
```



D'après ce camembert, nous constatons une proportion plus importante de personnes qui n'occupent pas d'emploi soit 85,6% tandis qu'il y a seulement 10,3% de personnes qui ne ne sont pas éligible au travail et 4,1% de personnes qui sont éligibles à occuper un emploi.

Tri à plat de la variable `tmpsorigine` (l'enquêté passe-t-il du temps avec des personnes ayant la même origine ?)

```
# Augmenter la taille du graphe
```

```
options(repr.plot.width=8, repr.plot.height=6)
```

```
# Variable 'tmpsorigine'
```

```
counts_tmpsorigine <- table(asile_4$tmpsorigine)
```

```
labels_tmpsorigine <- c("Fréquemment", "Occasionnellement", "Jamais")
```

```
colors_tmpsorigine <- c("green", "red", "yellow")
```

```
# Calculer les pourcentages
```

```
total_tmpsorigine <- sum(counts_tmpsorigine)
```

```
pourcentages_tmpsorigine <- counts_tmpsorigine / total_tmpsorigine * 100
```

```
# Tracer le graphique en camembert
```


```
pie(counts_tmpsorigine, col=colors_tmpsorigine, main="Temps passé avec des  
personnes de même origine", sub = "Répartition la variable 'tmpsorigine' ")
```

```
text_pie(pourcentages_tmpsorigine,
```

```
labels=paste0(round(pourcentages_tmpsorigine, 1), "%"), cex=1.1)
```

```
legend("topright", legend=labels_tmpsorigine, cex=0.7,
```

```
fill=colors_tmpsorigine, horiz=F)
```




D'après ce camembert, il y a une proportion majoritaire de personnes qui ont passé du temps de manière fréquente avec des personnes ayant la même origine. Par opposition, il y a seulement 24,8% de personnes qui ont passé du temps de manière occasionnel avec des personnes ayant la même origine et 16,1% jamais.

Tri à plat de la variable age (Age de l'enquêté au jour de l'enquête)

```
# Calculer les statistiques de résumé des boîtes
summary_stats <- boxplot.stats(asile_4$age)

# Créer le graphique de boîte avec outline = FALSE pour supprimer les points
aberrants
boxplot(asile_4$age, ylab = "Age", main = "Age de l'enquêté au jour de
l'enquête",
        col = "red", las = 1, outline = T, pos = -4)

# Ajouter les quartiles aux boîtes (décalage vers la droite)
text(1.2, summary_stats$stats[2], paste("Q1:", summary_stats$stats[2]), pos =
4, col = "blue", cex = 0.8)
text(1.2, summary_stats$stats[3], paste("Q2 (médiane):",
summary_stats$stats[3]), pos = 4, col = "blue", cex = 0.8)
text(1.2, summary_stats$stats[4], paste("Q3:", summary_stats$stats[4]), pos =
4, col = "blue", cex = 0.8)
```



D'après ce boxplot, le 1er quartile de cet effectif est l'âge de 26 ans, la médiane est de 32 ans c'est-à-dire qu'il y a autant de personnes qui ont un âge supérieur à 32 ans que de personnes qui ont un âge inférieur à 32 ans. Le 3ème quartile de cet effectif est l'âge de 40 ans et nous pouvons en déduire que l'intervalle interquartile est de 14 ans. Nous observons également des valeurs aberrantes, ce qui implique qu'il faut étudier plus en détail ces observations.


```
asile_4<-transform(asile_4, class_age=cut(age, breaks=quantile(age,
probs=c(0,0.25,0.5,0.75,1),include.lowest=TRUE, labels=1:4)))
```

```
#graphique des ages
```

```
# Créer Le graphique
graph <- barplot(table(asile_4$class_age), main="Répartition en classe
d'âge", xlab="Âge", ylab="Effectif", col="red", ylim=c(0,600))

# Calculer les pourcentages pour chaque modalité
pourcentages <- prop.table(table(asile_4$class_age)) * 100

# Ajouter Les pourcentages au-dessus des barres
text(x = graph, y = table(asile_4$class_age), labels =
paste0(round(pourcentages, 1), "%"), pos = 3, col = "black")
```



D'après ce graphique, il y a 26,5% des personnes qui sont âgées de 18 à 26 ans, 22,6% des personnes qui sont âgées de 26 à 32 ans, 23,7% des personnes qui sont âgées de 40 à 76 ans et 27,2% des personnes qui sont âgés de 32 à 40 ans.

3. Tris croisés de la variable y avec chacune des autres variables

Tri croisé de la variable y avec work

```
#tableau de contingence y*work
y_work <- table(asile_4$y,asile_4$work)
print(y_work)

##
##      non non éligible  oui
## non 1106           50  130
## oui  606           32   76

#test de chisq
chisq.test(y_work)

##
## Pearson's Chi-squared test
##
## data:  y_work
## X-squared = 0.59093, df = 2, p-value = 0.7442
```

Concernant le test du Khi-2 entre les variables work et sentiment de discrimination, nous avons $p\text{-value} = 0.7442 > 0,05$ donc nous acceptons l'hypothèse d'indépendance entre le fait de se sentir discriminer au moins une fois et le travail.

Tri croisé de la variable y avec tmpsorigine

```
#tableau de contegence y*tmpsorigine
y_tmpsorigine <- table(asile_4$y,asile_4$tmpsorigine)
print(y_tmpsorigine)

##
##      fréquemment occasionnellement  jamais
## non           755                313   218
## oui           428                182   104

#test de chisq
chisq.test(y_tmpsorigine)

##
## Pearson's Chi-squared test
```



```
##
## data: y_tmpsorigine
## X-squared = 1.9875, df = 2, p-value = 0.3702
```

Concernant le test du Khi-2 entre les variables origine et sentiment de discrimination, nous avons $p\text{-value} = 0.3702 < 0,05$ donc nous rejetons l'hypothèse d'indépendance entre le sentiment de discrimination et tmporigine, il existe une relation de dépendance entre le temps passé par l'enquête avec des personnes ayant la même origine.

Tri croisé de la variable y avec tmpsallemand

```
#tableau de contingence y*tmpsallemand
y_tmpsallemand <- table(asile_4$y,asile_4$tmpsallemand)
print(y_tmpsallemand)

##
##      fréquemment occasionnellement jamais
## non      734             286      266
## oui      413             182      119

#test de chisq
chisq.test(y_tmpsallemand)

##
## Pearson's Chi-squared test
##
## data: y_tmpsallemand
## X-squared = 5.9699, df = 2, p-value = 0.05054
```

Concernant le test du Khi-2 entre les variables tmpsallemand et sentiment de discrimination, nous avons $p\text{-value} = 0.05054 > 0,05$ donc nous acceptons l'hypothèse d'indépendance entre le sentiment de discrimination et le temps passé par l'enquête avec des personnes allemandes.

Tri croisé de la variable y avec speak_german

```
#tableau de contenance y*speak_german
y_speak_german <- table(asile_4$y,asile_4$speak_german)
print(y_speak_german)

##
##      oui non
## non 611 675
## oui 403 311

#test de chisq
chisq.test(y_speak_german)
```

```
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data: y_speak_german
## X-squared = 14.295, df = 1, p-value = 0.0001563
```

Concernant le test du Khi-2 entre les variables `speak_german` et sentiment de discrimination, nous avons $p\text{-value} = 0.0001563 > 0,05$ donc nous acceptons l'hypothèse d'indépendance entre le sentiment de discrimination et le temps passé par l'enquête avec des personnes allemandes.

Tri croisé de la variable y avec exclu

```
#tableau de contingence y*exclu
y_exclu <- table(asile_4$y,asile_4$exclu)
print(y_exclu)

##
##      fréquemment occasionnellement jamais
## non      211             570      505
## oui      206             379      129

#test de chisq
chisq.test(y_exclu)

##
## Pearson's Chi-squared test
##
## data: y_exclu
## X-squared = 106.62, df = 2, p-value < 2.2e-16
```

Concernant le test du Khi-2 entre les variables `exclu` et sentiment de discrimination, nous avons $p\text{-value} < 2.2e-16 < 0,05$ donc nous rejetons l'hypothèse d'indépendance entre le sentiment de discrimination et de se sentir exclu.

Tri croisé de la variable y avec ind_origine

```
#tableau de contingence y*ind_origine
y_ind_origine <- table(asile_4$y,asile_4$ind_origine)
print(y_ind_origine)

##
##      oui non
## non 676 610
## oui 348 366

#test de chisq
chisq.test(y_ind_origine)
```

```
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data: y_ind_origine
## X-squared = 2.5396, df = 1, p-value = 0.111
```

Concernant le test du Khi-2 entre les variables exclu et sentiment de discrimination, nous avons $0,111 > 0,05$ donc nous rejetons l'hypothèse d'indépendance entre le sentiment de discrimination et de d'être d'origine syrienne.

Tri croisé de la variable y avec integrationcourse

```
#tableau de contenance y*integrationcourse
y_integrationcourse <- table(asile_4$y,asile_4$integrationcourse)
print(y_integrationcourse)

##
##      oui non
## non 417 869
## oui 276 438

#test de chisq
chisq.test(y_integrationcourse)

##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data: y_integrationcourse
## X-squared = 7.5949, df = 1, p-value = 0.005853
```

Concernant le test du Khi-2 entre les variables exclu et sentiment de discrimination, nous avons $0,005853 < 0,05$ donc nous avons une relation de dépendance entre le sentiment de discrimination et de suivre des cours d'intégration.

4.Réalisation de l'équivalent de la question 3 pour les deux variables y et age

```
#segmentation en classes d'age
#creation d'une nouvelle variable qualitative ageclass
asile_4$ageclass <- cut(asile_4$age, breaks = c(0, 26, 32, 40, 100), labels
= c("jeune_age", "-jeune_age", "moyen_age", "plus_agé"))
#affichage du résumé
summary(asile_4$ageclass)
```

```
##   jeune_age -jeune_age   moyen_age   plus_agé
##         566         441         530         463

#
y_ageclass <- table(asile_4$y, asile_4$ageclass)
print(y_ageclass)

##
##      jeune_age -jeune_age   moyen_age   plus_agé
##   non         324         288         347         327
##   oui         242         153         183         136

chisq.test(y_ageclass)

##
##  Pearson's Chi-squared test
##
## data:  y_ageclass
## X-squared = 20.861, df = 3, p-value = 0.0001125
```

Concernant le test du Khi-2 entre les variables exclu et sentiment de discrimination, nous avons $0,0001125 < 0,05$ donc nous avons une relation de dépendance entre le sentiment de discrimination et l'âge.

5. Modélisation de y par les variables âge et sexe suivant un modèle logistique additif

$$P(Y = 1 | \widehat{\text{âge}}, \text{sexe}) = \frac{e^{\beta_0 + \beta_1 \times \widehat{\text{âge}} + \beta_2 \times \text{ind_homme}}}{1 + e^{\beta_0 + \beta_1 \times \widehat{\text{âge}} + \beta_2 \times \text{ind_homme}}}$$

Avec comme hypothèses que tous les Y_i sont de loi de Bernoulli identiquement indépendantes de probabilité $\pi(X_i)$. Le coefficient β_0 signifie l'intercept de la ligne de régression logistique, il représente aussi la valeur du logarithme de nos odds estimés lorsque les variables explicatives du modèle valent toutes 0. Le coefficient β_1 représente le coefficient associé à l'âge et aussi l'augmentation ou la diminution du log-odds-radio entre la modalité 0 et la modalité 1 de ressentir une discrimination au moins une fois pour chaque année d'augmentation de l'âge. Le coefficient β_2 représente le coefficient associé à l'indicatrice de la modalité "homme" de la variable sexe. Il représente aussi la différence entre le logarithme de l'odds ratio associé de ressentir de la discrimination au moins une fois selon le sexe.

6. Estimation du modèle précédent

On s'intéresse à l'effet d'être un homme par rapport au fait d'être une femme dans le modèle donc on doit considérer que la modalité "femme" soit la modalité de référence.

```

library(forcats)
asile_4$sexe=as.character(asile_4$sexe) #pour que la fonction reconnaisse les
différentes modalités

asile_4$sexe=fct_recode(asile_4$sexe, "homme" = "1", "femme" = "2")

asile_4$sexe=fct_relevel(asile_4$sexe,c( "femme", "homme"))

summary(asile_4$sexe)

## femme homme
##    769   1231

# Estimer le modèle logistique
model_y <- glm(y ~ age + sexe, data = asile_4, family = binomial(link =
"logit"))
print(model_y)

##
## Call:  glm(formula = y ~ age + sexe, family = binomial(link = "logit"),
##      data = asile_4)
##
## Coefficients:
## (Intercept)          age      sexehomme
##   -0.13614    -0.01795     0.23222
##
## Degrees of Freedom: 1999 Total (i.e. Null);  1997 Residual
## Null Deviance:      2607
## Residual Deviance: 2585  AIC: 2591

```

En fixant un niveau de significativité à 5%, les coefficients β_0 , β_1 et β_2 du modèle logistique sont significativement différents de 0 où les β_i sont associés à l'intercept, l'âge et l'homme. Les coefficients β_i supérieurs à 0 auront un ODDS-Ratio > 1, soit la probabilité de se sentir discriminer au moins une fois qui est plus élevée par rapport à la modalité de référence qui est la femme. Les coefficients β_i inférieurs à 0 auront un ODDS-Ratio < 1, soit la probabilité de se sentir discriminer au moins une fois qui est moins élevée par rapport à la modalité de référence qui est la femme. On constate que le coefficient β_2 est significativement différent de 0 et supérieur à 0 donc il aura un ODDS-Ratio supérieur à 1, cela signifie que les hommes ayant déposé une demande d'asile entre janvier 2013 et janvier 2016 ont une probabilité de se sentir discriminer au moins une fois supérieure aux femmes ayant déposé une demande d'asile.

7. Estimation de la probabilité p (sentiment d'avoir été discriminé au moins une fois)

```

individu_homme <- data.frame(age = 30, sexe = "homme") # L'individu homme
de 30 ans
individu_homme

```

```
##   age  sexe
## 1  30 homme

# Estimer la probabilité
prob_homme <- predict(model_y, newdata = individu_homme, type = "response")
prob_homme

##           1
## 0.3911763
```

Pour un individu homme âgé de 30 ans, la probabilité d'avoir le sentiment d'avoir été discriminé au moins une fois est de 0.3911763.

8. Construction d'un vecteur contenant les valeurs prédites

```
# Définir le seuil
pseuil <- 0.2

# Obtenir les probabilités prédites pour chaque individu
probabilites <- predict(model_y, newdata = asile_4, type = "response")

# Appliquer la règle de resubstitution pour obtenir les prédictions
y_prdic <- ifelse(probabilites > pseuil, "oui_discri", "non_discri")
```

9. Le tableau de contingence croisant les valeurs observées et les valeurs prédites

```
mat_conf <- table(asile_4$y, y_prdic)
mat_conf

##      y_prdic
##      non_discri oui_discri
## non           3      1283
## oui           0       714
```

On peut appeler cette table la matrice de confusion car la prédiction peut résulter des erreurs ce qui permet d'évaluer correctement l'efficacité de notre modèle. Également la matrice de confusion permet de déterminer si la classification est bonne ou non. On peut constater que la prédiction a été bonne pour un nouvel individu concernant son sentiment de discrimination

10. Calcul des différentes quantités

❖ Taux de mauvais classement

- ❖ Sensibilité ou taux de vrais positifs
- ❖ Spécificité ou taux de vrais négatifs

```

VP <- mat_conf[2,2]
FP <- mat_conf[2,1]
VN <- mat_conf[1,1]
FN <- mat_conf[1,2]

t_mauvaisclassement <- (FP+FN)/nrow(asile_4)
t_mauvaisclassement

## [1] 0.6415

t_vrais_positifs <- VP / (VP+FN)
t_vrais_positifs

## [1] 0.3575363

t_vrais_négatifs <- VN / (VN + FP)
t_vrais_négatifs

## [1] 1

```

Le taux de mauvais classement est de 64,15% Le taux de vrais positifs est de 35,75% c'est-à-dire la proportion des personnes qui ont été estimées comme ayant subi de la discrimination au moins une fois et ayant réellement été discriminé au moins une fois Le taux de vrais négatifs est de 1% c'est-à-dire la proportion des personnes qui ne se sentent pas discriminées et n'ayant pas réellement été discriminé au moins une fois.

La spécificité est décrit par $P(Y_{chap}=0/Y=0)$ donc l'opposé de la spécificité s'exprime par $P(Y_{chap}=1/Y=0)=1-P(Y_{chap}=0/Y=0)$ qui est le taux de faux positifs, c'est-à-dire le nombre de personnes qui ont été prédites comme ayant subi de la discrimination au moins une fois alors qu'en vrai, elles n'ont pas vécu de sentiment de discrimination au moins une fois.

11. Validation croisée

Définir à partir du data.frame `asile_4` deux data frames

```

n=2000
sel_lignes<-sample(1:n,1200)
asile_4_app<-asile_4[sel_lignes,] # Extraction de asile_4 La sélection des
lignes afin de pouvoir créer du dataframe asile_4_app
lignes_nonsel <- setdiff(1:n, sel_lignes) #on crée un vecteur qui prend en
compte les lignes non sélectionnées dans le vecteur sel_lignes
asile_4_val<- asile_4[lignes_nonsel, ] # Ensuite on range ces lignes dans le
vecteur asile_4_val

```

Estimation du modèle logistique à partir de asile_app

```
# Estimation du modèle logistique à partir de asile_app
modele_app<-glm(y ~ age + sexe , family=binomial(link =
"logit"),data=asile_4_app)
summary(modele_app)

##
## Call:
## glm(formula = y ~ age + sexe, family = binomial(link = "logit"),
##      data = asile_4_app)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -0.209397   0.223726  -0.936   0.3493
## age          -0.016237   0.005999  -2.707   0.0068 **
## sexehomme     0.256747   0.125177   2.051   0.0403 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 1562.4  on 1199  degrees of freedom
## Residual deviance: 1550.3  on 1197  degrees of freedom
## AIC: 1556.3
##
## Number of Fisher Scoring iterations: 4
```

estimation du taux de mauvais classement sur la table asile_val

```
pseuil2 <- 0.2

# Obtenir les probabilités prédites pour chaque individu
probabilites2 <- predict(modele_app, newdata = asile_4_val, type =
"response")

# Appliquer la règle de resubstitution pour obtenir les prédictions
predictions2 <- ifelse(probabilites2 > pseuil2, "predi_oui_discr",
"predi_non_discr")

tab_cont_val<-table(asile_4_val$y, predictions2)
tab_cont_val
```



```
##      predictions2
##      predi_non_discri predi_oui_discri
##      non              1              512
##      oui              0              287

Vrai_pos2 <- tab_cont_val[2,2]
Faux_pos2 <- tab_cont_val[2,1]
Vrai_neg2 <- tab_cont_val[1,1]
Faux_neg2 <- tab_cont_val[1,2]
# mauvais classement
tchapeau_val=(Faux_pos2 + Faux_neg2)/800
tchapeau_val

## [1] 0.64

# sensibilité
sechapeau_val=Vrai_pos2 / (Vrai_pos2 + Faux_neg2)
sechapeau_val

## [1] 0.359199

# spécificité
spchapeau_val=Vrai_neg2 / (Vrai_neg2 + Faux_pos2)
spchapeau_val

## [1] 1
```

Nous avons créé des data frames en effectuant un tirage de manière aléatoire de la table asile_4 tout en sélectionnant 800 individus parmi les 2000 individus, qui constitueront l'effectif de validation. Nous constatons que le taux de mauvais classement passe de 64,15% à 64% soit une diminution d'environ 0,15%. Nous constatons que la sensibilité passe de 35,75% à 35,92% soit une légère augmentation d'environ 0,17%. Nous constatons que la spécificité reste à 1%.

12. Constuction de la courbe ROC

```
library("pROC")

## Warning: le package 'pROC' a été compilé avec la version R 4.3.3
## Type 'citation("pROC")' for a citation.
##
## Attachement du package : 'pROC'
## Les objets suivants sont masqués depuis 'package:stats':
##
##      cov, smooth, var
```

```

Roc<-roc(asile_4$y, model_y$fitted.values, legacy.axes=T, xlab="Taux de faux-positifs", ylab="Taux de vrais-positifs")

## Setting levels: control = non, case = oui

## Setting direction: controls < cases

seuils=seq(0,1,0.01) #création du vecteur allant de 0 à 1 avec un pas de 0.01
ROC<-data.frame(vrai_pos=Roc$sensitivities*100, faux_pos=(1-
Roc$specificities)*100, pseuil=Roc$thresholds)
ROC$youden<-Roc$sensitivities+Roc$specificities-1 # index de youden qui maximise les vrais positifs et minimise les faux négatifs
index_youden<-max(ROC$youden)
ROC$pseuil[ROC$youden==index_youden]

## [1] 0.3576902

```

L'index de Youden est une mesure de la précision de la méthode de diagnostic. Il dépend de la spécificité et de la sensibilité du test. Il représente la maximisation de la sensibilité et minimise les faux positifs L'index de Youden est atteint au seuil 0,36.

```

ROC$vrai_pos[ROC$youden==index_youden] # Nous avons une sensibilité d'environ 68%


## [1] 56.58263

ROC$faux_pos[ROC$youden==index_youden] # Nous avons un taux de faux positifs d'environ 58%

## [1] 44.71229

plot(ROC$faux_pos,ROC$vrai_pos, main="Courbe ROC", xlab="Vrais-positifs", ylab="Faux-positifs",col=("blue"))

```



13. Ajout d'une des variables inutilisées dans le modèle initial

Nous formulons des hypothèses de départ :

- ❖ H0 : La variable n'est pas interprétable
- ❖ H1 : La variable est interprétable

Si la p-valeur du test est inférieure à 5%, alors nous rejetterons H0.

Si la p-valeur du test est supérieure à 5%, alors nous accepterons H0.

13.1 Ajout de la variable Work

La discrimination à l'embauche fait partie des cas de discrimination en France car des personnes ne remplissent pas forcément des critères donc il serait intéressant d'étudier ce phénomène en Allemagne et donc de rajouter la variable work à notre modèle.

```
asile_4$work=as.character(asile_4$work) #pour que la fonction reconnaisse les
différentes modalités
library(forcats)
asile_4$work=fct_relevel(asile_4$work,c("non","non éligible", "oui")) # On
choisit "non" comme modalité de référence car c'est la plus présente chez nos
individus
modele_work=glm(y ~ age + sexe + work , family=binomial(link =
```

```

"logit"),data=asile_4)
summary(modele_work)

##
## Call:
## glm(formula = y ~ age + sexe + work, family = binomial(link = "logit"),
##      data = asile_4)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -0.139639    0.173800  -0.803  0.421717
## age           -0.017874    0.004667  -3.830  0.000128 ***
## sexehomme      0.232704    0.098735   2.357  0.018430 *
## worknon éligible 0.064343    0.235858   0.273  0.785005
## workoui       -0.018587    0.155814  -0.119  0.905047
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 2606.7  on 1999  degrees of freedom
## Residual deviance: 2585.4  on 1995  degrees of freedom
## AIC: 2595.4
##
## Number of Fisher Scoring iterations: 4

```

La p-valeur du coefficient associé à la modalité worknon éligible est de 0,659718 > 0,05 donc la modalité worknon éligible n'est pas interprétable. la p-valeur du coefficient associé à la modalité workoui est de 0,808154 > 0,05 donc la modalité workoui n'est pas interprétable. Par conséquent, prédire le fait d'avoir été discriminé au moins une fois en incluant la variable work n'a pas vraiment de sens. Nous allons changer de modèle.

13.2 Ajout de la variable ind_origine

Nous allons rajouter la variable ind_origine car on sait que l'origine fait partie des cas de discrimination les plus fréquemment observées

<https://www.histoire-immigration.fr/economie-et-immigration/quelles-sont-les-victimes-des-discriminations-fondees-sur-l-origine-dans-l-emploi>

D'après différentes enquêtes, les victimes de discriminations raciales touchent les populations d'origine étrangère, principalement les jeunes, nés en France pour la plupart, et de nationalité française. Parmi ces jeunes, les enfants de parents immigrés originaires du Maghreb et d'Afrique Subsaharienne sont les plus touchés dans l'emploi. On choisit "oui" comme modalité de référence car c'est la plus présente chez nos individus d'après le tri à plat effectué auparavant.

```

modele_ind_origine=glm(y ~ age + sexe + ind_origine, family=binomial(link =
"logit"),data=asile_4)
summary(modele_ind_origine)

```

```
##
## Call:
## glm(formula = y ~ age + sexe + ind_origine, family = binomial(link =
"logit"),
##     data = asile_4)
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -0.220477   0.181250  -1.216  0.223823
## age          -0.017638   0.004664  -3.782  0.000155 ***
## sexehomme     0.236612   0.097379   2.430  0.015107 *
## ind_origineon  0.144447   0.094013   1.536  0.124427
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 2606.7  on 1999  degrees of freedom
## Residual deviance: 2583.1  on 1996  degrees of freedom
## AIC: 2591.1
##
## Number of Fisher Scoring iterations: 4

asile_4$ind_origine=as.character(asile_4$ind_origine)
asile_4$ind_origine=fct_relevel(asile_4$ind_origine,c("non","oui"))
modele_ind_origine=glm(y ~ age + sexe + ind_origine, family=binomial(link =
"logit"),data=asile_4)
summary(modele_ind_origine)

##
## Call:
## glm(formula = y ~ age + sexe + ind_origine, family = binomial(link =
"logit"),
##     data = asile_4)
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -0.076030   0.177031  -0.429  0.667579
## age          -0.017638   0.004664  -3.782  0.000155 ***
## sexehomme     0.236612   0.097379   2.430  0.015107 *
## ind_origineoui -0.144447   0.094013  -1.536  0.124427
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 2606.7  on 1999  degrees of freedom
## Residual deviance: 2583.1  on 1996  degrees of freedom
## AIC: 2591.1
```

```
##
## Number of Fisher Scoring iterations: 4
```

Encore une fois, nous avons une p -valeur $= 0.124427 > 0,05$ donc la variable `ind_origine` n'est pas interprétable. Par conséquent, prédire le fait d'avoir été discriminé au moins une fois en incluant la variable `ind_origine` n'a pas vraiment de sens. Nous allons à nouveau changer de modèle en rajoutant une autre variable parmi le jeu de données.

13.3 Ajout de la variable `speak_german`

Nous allons rajouter la variable `speak_german` car il existe de la discrimination linguistique dans plusieurs pays du monde notamment pour accéder à un emploi, dans le milieu éducatif avec le rejet de l'autre donc il serait pertinent d'étudier ce phénomène en Allemagne pour savoir si le fait de parler la langue allemande exerce une influence sur le fait d'avoir été discriminé au moins une fois.

```
modele_speak_german=glm(y ~ age + sexe + speak_german , family=binomial(link
= "logit"),data=asile_4)
summary(modele_speak_german)

##
## Call:
## glm(formula = y ~ age + sexe + speak_german, family = binomial(link =
"logit"),
##     data = asile_4)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -0.068103   0.174690  -0.390   0.69665
## age          -0.015342   0.004755  -3.227   0.00125 **
## sexehomme      0.190625   0.098570   1.934   0.05312 .
## speak_germannon -0.268212   0.097148  -2.761   0.00577 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 2606.7  on 1999  degrees of freedom
## Residual deviance: 2577.8  on 1996  degrees of freedom
## AIC: 2585.8
##
## Number of Fisher Scoring iterations: 4
```

Concernant les modalités relatives à la langue du pays, tous les coefficients sont interprétables car ils ont tous une p -valeur inférieure à 5%. Le coefficient de la variable âge est également interprétable hormis l'intercept et `sexehomme`. Le coefficient associé à l'âge est de valeur négative (-0,01536) donc nous pouvons considérer que l'âge exerce une influence négative sur le fait d'avoir été discriminé au moins une fois. Plus l'âge augmente plus le sentiment d'avoir été

discriminé au moins une fois augmente. De plus, le coefficient associé à la modalité `speak_germannon` est négatif (-0.29848) donc nous pouvons considérer que le fait de ne pas parler allemand a une influence négative sur le fait d'avoir été discriminé au moins une fois. Une personne ne parlant pas allemand se sentira moins discriminé au moins une fois qu'une personne parlant l'allemand.