

Mesurer les migrations internationales : à la recherche des valeurs aberrantes

Gestion de projet - MASS POP Master 2

Année : 2024 /2025

Équipe de projet :

- **Mathieu GRONDIN**
- **Arezki HASSAK**
- **Ablaye Sow SIDIBE**

Encadrants :

- **Arnaud BRINGE**
- **Cris BEAUCHEMIN**

Table des matières

I.	Contexte et problématique du projet (ABIMS).....	1
1.	Présentation du projet ABIMS	1
2.	Descriptif et rôle des Organisations Internationales (UN, WB, OECD et EU).....	1
3.	Hypothèses	2
4.	Préparation des données	3
5.	Prétraitement des données	4
II.	Données et Méthodes	6
1.	Analyse intra-sources (WB)	6
2.	Analyse intra-sources (UN).....	7
3.	Analyse intra-sources (EU)	9
4.	Analyse intra-sources (OECD).....	9
5.	Fusion des (UN, WB, EU, OECD).....	11
6.	Analyse inter-sources après fusion.....	12
III.	Traitement de données	13
1.	Identifier et analyser les observations aberrantes.....	13
IV.	Conclusion.....	20
V.	Bibliographie	21

I. Contexte et problématique du projet (ABIMS)

1. Présentation du projet ABIMS

Le projet de recherche ABIMS (Aggregated Base of International Migrants Stocks) est la présentation d'une nouvelle base de données comparative qui nous permet de comparer les estimations de stocks de migrants internationaux produits par diverses institutions telles que les Nations Unies, La Banque Mondiale, Eurostat et l'OCDE sur le sujet des migrations internationales. Les premières analyses [REF] montrent des écarts significatifs dans la mesure des stocks de migrants internationaux selon les sources. Certaines estimations, à l'échelle des couples origine-destination s'écartent radicalement des autres et peuvent être considérées comme aberrantes. Nous allons illustrer quelques exemples de couples origine-destination. Il nous est demandé de proposer une méthode pour identifier de façon systématique les valeurs « aberrantes » dans les matrices bilatérales de migration, qui estiment les stocks de migrants internationaux par origine et destination, à l'échelle des 215 pays ou territoires de la planète. L'objectif est double : quantifier l'importance relative des mesures aberrantes et analyser les facteurs expliquant l'existence de ces estimations problématiques.

Les analyses se décomposent en deux échelles : (1) comparaisons intra-source entre les différentes estimations d'un même producteur, et que ce producteur possède différentes bases de données en fonction de l'origine des données collectées, de différents facteurs notamment socio-économiques, démographiques ; (2) comparaisons inter-sources entre les bases des différents producteurs.

2. Descriptif et rôle des Organisations Internationales (UN, WB, OECD et EU)

Les migrations internationales sont un phénomène majeur qui façonne les économies, les sociétés et les politiques à l'échelle mondiale. Plusieurs organisations collectent et diffusent des données pour mieux comprendre les flux migratoires et leurs impacts.

Les principales bases de données sont produites par :

- **Nations Unies (ONU)** – Vue globale des migrations et des réfugiés.
- **OCDE** – Flux migratoires et intégration dans les pays développés.
- **Banque Mondiale** – Impact économique et remises migratoires.
- **Eurostat** – Statistiques sur les migrations en Europe.

Grâce aux données fournies par ces organisations, il est possible de suivre et d'analyser les dynamiques migratoires, leur impact socio-économique et les politiques mises en place.

La Banque Mondiale (WB) est une organisation qui s'intéresse aux migrations principalement sous l'angle économique et du développement. Son objectif est d'évaluer comment les migrations influencent la croissance, la réduction de la pauvreté et les inégalités entre les pays. La Banque Mondiale (WB) considère que les migrations peuvent contribuer au développement des pays, notamment d'origine, d'où :

- la 1ère base concentrée sur les migrations de travail (qui exclut les réfugiés)
- les bases Knomad, qui relevaient d'un projet de mesure des « remittances »
- la dernière base associée au World Development report.

Eurostat est l'office statistique de l'Union Européenne. Il est chargé de fournir des statistiques et des données de haute qualité sur une large série de domaines à propos de l'Europe. Elle s'intéresse aux migrations principalement pour suivre et analyser les dynamiques migratoires en Europe et aider à l'élaboration des politiques européennes en matière de migration, d'asile et d'intégration.

L'OCDE (Organisation de coopération et de développement économiques) analyse les tendances migratoires et leurs impacts économiques et sociaux. Elle fournit des données, des recommandations et des rapports pour aider les gouvernements à élaborer des politiques migratoires efficaces. Son action se concentre sur :

- L'analyse des flux migratoires : Elle suit l'évolution des migrations internationales et leur impact sur les marchés du travail.
- L'intégration des migrants : Elle étudie leur insertion professionnelle et sociale dans les pays d'accueil.
- Les politiques migratoires : Elle compare les approches des pays membres et propose des bonnes pratiques.
- Les liens entre migration et développement : Elle examine comment la migration influence les pays d'origine et de destination.

3. Hypothèses

Les explorations qui ont été menées pour cette étude ont montré qu'il existe des écarts d'une source à une autre (Bauchemin et al. 2023). Ces écarts peuvent s'expliquer par les différentes définitions de ce que c'est un migrant international. D'une part, un migrant international est une personne qui n'est pas né dans le pays où il réside, et d'autre part, un migrant international est une personne qui a une nationalité différente du pays de résidence. Par ces deux définitions, nous observons qu'il y a une différence d'appréciation de ce qu'est un migrant international et

qu'il est important de s'intéresser sur le critère utilisé par la source d'organisation internationale pour définir le pays d'origine : pays de naissance ou nationalité. Il est préférable de privilégier le pays de naissance par rapport à la nationalité étant donné que certaines personnes peuvent avoir la double nationalité ou qu'il peut y avoir des règles différentes de l'acquisition de la nationalité selon les différents pays.

Suite à cela, nous pouvons indiquer la première hypothèse :

(H1) : Les sources d'écarts des stocks de migrants internationaux peuvent s'expliquer par des écarts, entre sources, dans la définition des migrants internationaux.

Depuis le début de la guerre civile en Syrie en 2011, le pays a connu une migration massive de sa population. Des millions de Syriens ont été forcés de fuir en raison des violences, des bombardements et de la destruction des infrastructures. Cette situation a provoqué une variation soudaine et anormale des stocks de migrants, particulièrement dans les pays voisins comme la Turquie, le Liban, la Jordanie, et au sein de l'Union Européenne.

(H2) : Les conflits armés peuvent provoquer des changements brusques et inhabituels dans les flux migratoires, entraînant ainsi des variations anormales des stocks de migrants.

Les dynamiques territoriales influencent considérablement les flux migratoires, en particulier dans des espaces caractérisés par des statuts géopolitiques spécifiques, comme les territoires d'Outre-mer. La Guyane, département français situé en Amérique du Sud, constitue un exemple frappant de ces variations migratoires atypiques, notamment en raison de sa position stratégique et de son attractivité économique régionale.

(H3) : Les dynamiques territoriales, telles que les territoires d'Outre-mer, les regroupements ou les éclatements de pays, peuvent être à l'origine de variations inhabituelles dans les stocks de migrants internationaux.

4. Préparation des données

Une grande partie des bases de données des principaux producteurs, tels que l'OCDE, la Banque mondiale, les Nations Unies et Eurostat, a été préparée et documentée par notre encadrant Arnaud Bringé sous forme de fichiers Excel et RData. Ces bases permettent d'analyser les dynamiques migratoires, notamment en mettant en évidence l'influence des évolutions territoriales. En effet, des facteurs tels que les territoires d'Outre-mer, les regroupements ou les éclatements de pays peuvent être à l'origine de variations inhabituelles dans les stocks de migrants internationaux. Nous avons complété ces bases là en rajoutant le typage des données des stocks de la Banque Mondiale. De plus, nous avons effectué des fusions des bases de l'OECD pour en faire une base unique. Même chose pour la Banque Mondiale.

Les données utilisées dans ce rapport proviennent de plusieurs bases de référence élaborées par des organismes internationaux tels que l'ONU, la Banque mondiale et l'OCDE. La base des Nations Unies (UN) propose des estimations des stocks de migrants internationaux ventilées par âge, sexe et pays ou région d'origine, basées principalement sur des recensements, des

registres de population et des enquêtes nationales. Elle couvre la période 1990-2020 avec des mises à jour tous les cinq ans et distingue les migrants selon quatre types de données : population née à l'étranger (B), citoyens étrangers (C), réfugiés et assimilés (R), et imputations en l'absence de données (I).

La Banque mondiale (WB) fournit plusieurs bases, notamment la Global Bilateral Migration Database (GMDB) qui couvre les flux migratoires bilatéraux de 1960 à 2020. Les estimations reposent principalement sur les recensements et registres de population, bien que ceux-ci soient souvent limités aux pays à revenus élevés et excluent les migrants sans papiers. La méthodologie de la Banque mondiale privilégie les données par pays de naissance, conformément aux pratiques de l'ONU.

L'OCDE met à disposition des bases comme l'« International Migration Database » et la DIOC, qui offrent des données sur les stocks de migrants par pays d'origine et de destination de 1995 à 2023. Les données sont typées selon deux critères : la nationalité et le pays de naissance. Certaines années présentent des limites en raison de la disponibilité des données, ce qui a nécessité des ajustements méthodologiques.

La base de données Eurostat.xlsx couvre les stocks de migrations internationales de 1998 à 2023, avec un typage des données basé sur la nationalité (Citizenship) et le pays de naissance (Country of Birth). Certaines anomalies ont nécessité des ajustements : suppression des lignes où le pays d'origine et le pays de destination sont identiques, ainsi que des agrégats ne correspondant pas à des codes de pays ISO3. Lorsqu'une migration est enregistrée avec les deux types de données sur une même année, la priorité a été donnée au pays de naissance. En revanche, lorsqu'un seul critère est disponible, il a été conservé tel quel.

5. Prétraitement des données

Pour chaque producteur, nous avons créé des variables indicatrices pour définir le typage des données afin de comprendre quels ont été les critères sur lesquels les données ont été comptabilisées. Ces variables indicatrices créées sont définies de la manière suivante :

- country_born : Pays de naissance
- Nationality : Nationalité
- Refugee : Réfugié
- Imputation : Imputation

De plus, nous avons supprimé, tous les agrégats qui ne sont pas des ISO3 pour éviter les doublons, les lignes où les pays d'origine sont aussi les pays de destination car ces stocks correspondent à des personnes nées dans un pays et qui habitent dans ce même pays et donc ils ne sont pas des migrants.

Pour le producteur OCDE, lorsque nous avons un couple de pays où, sur la même année, nous avons comme typage, Birth_Country (Pays de naissance) et Citizenship (Nationalité), nous

avons privilégié le typage du pays de naissance et donc nous avons supprimé la ligne qui correspond au typage de la nationalité. Pour obtenir la base unique de l'OCDE, nous avons assemblé la base principale « International migration database » qui a été reformulé et préparé dans le fichier OECD_IMDB.xlsx, avec la base DIOC, où l'on a utilisé un seul fichier Excel pour chaque année : 2000/01, 2010/11, 2015/16, 2020/21, et avec la base DIOC-E de l'année 2010/11. Nous n'avons pas pris en compte pour celle de l'année 2020/21 car il n'y a pas de données disponibles.

Pour obtenir la base unique de la Banque Mondiale, nous avons assemblée la base principale WDR_2023 avec la base WB_GMDB_11 et avec les fichiers Knomad : WB_Kd_2010, WB_Kd_2017 et WB_Kd_2021. De plus, nous avons intégré les typages des données à l'aide de l'annexe 1 de Özden, Çağlar, Christopher R. Parsons, Maurice Schiff, et Terrie L. Walmsley. 2011. « Where on Earth is Everybody? The Evolution of Global Bilateral Migration 1960–2000 ». *The World Bank Economic Review* 25(1):12-56., et nous les avons copié-collé sur un fichier Excel. Puis en utilisant le package Country Code, nous avons fusionné cette base Excel avec la base historique WB_GMDB_11. Aussi, vu que nous avons constaté que les typages des données de la Banque Mondiale viennent de ceux des Nations Unies de 1990 à 2020, nous avons importé les typages des Nations Unies pour les intégrer dans la base unique de la Banque Mondiale.


En ce qui concerne les Nations Unies, nous avons en notre possession la base UN.xlsx déjà préparé par nos encadrants, et il a suffi de créer des indicatrices pour le typage des données, comme préciser au début de cette étape du prétraitement des données.

Pour Eurostat, nous avons un fichier Eurostat.xlsx déjà préparé avec des pays ayant un code ISO2 que l'on a ensuite transformé en ISO3 à l'aide du package Country Code, et nous avons également supprimé, tous les agrégats qui ne sont pas des ISO3 pour éviter les doublons, les lignes où les pays d'origine sont aussi les pays de destination. Dans le cas où, sur la même année, on a les 2 typages : country_born et Nationality, nous avons gardé country_born, autrement dit, le pays de naissance.

II. Données et Méthodes

1. Analyse intra-sources (WB)

Cas du couple Syrie-Turquie




Par lecture graphique, nous constatons que le stock de migrants de la source WDR_2023 connaît une augmentation spectaculaire après 2010 avec une observation de stock très éloignée des autres observations sur l'année 2020, donc on pourrait suspecter que cette valeur est anormale et qu'elle peut représenter une valeur aberrante.

Cas du couple Brésil - France métropolitaine et Brésil - Guyane

Ici selon la base « undesa_pd_2020_ims_stock_by_sex_destination_and_origin.xlsx », illustrant la matrice de migration mondiale, à des fins statistiques, la population née à l'étranger comprend les personnes nées dans les régions de France métropolitaine et en Guyane française.

Nous avons représenté graphiquement les stocks des migrations internationales avec comme pays de départ le Brésil et comme pays d'arrivée la France métropolitaine, en fonction des années de la période 1960-2023.



Par lecture graphique, nous constatons qu'il y a une différence de stocks entre 1960 et 2000 entre les sources internes et une différence entre les sources internes WB_Kd et WDR_2023, qui prennent en compte uniquement le pays de naissance qui prennent en compte uniquement le pays de naissance.

Ensuite, concernant la Guyane, étant donné que celle-ci n'est pas comptabilisée dans les données de la France métropolitaine, et nous avons seulement les données provenant d'une seule source interne WB_GMDB_11 donc il n'est pas pertinent de s'interroger sur des éventuelles valeurs aberrantes étant donné que nous ne pouvons pas obtenir des écarts entre plusieurs sources intra.


2. Analyse intra-sources (UN)

Ici, à travers la base de données, nous étudions les éventuels écarts des stocks de migrations internationales entre les différentes sources internes actualisées : UN_2015, UN_2017, UN_2019 et UN_2020.

Cas du couple Syrie - Turquie

Toujours dans le cas où l'on a comme pays d'origine, la Syrie, et comme pays de destination, la Turquie. Nous avons représenté graphiquement les stocks des migrations internationales avec comme pays de départ la Syrie et comme pays d'arrivée la Turquie, en utilisant comme typage des données, le type B, signifiant le pays de naissance et le type R, signifiant le statut de réfugié, en fonction des années de la période 1990-2020.

1.




Par lecture graphique, nous observons des écarts de stocks de migrations internationales entre la Turquie et la Syrie durant le milieu de l'année 2015. On peut émettre l'hypothèse que la sous-estimation de 2015 s'explique par la quasi simultanéité entre l'exode de 2015 et l'estimation de 2015 : les estimations, réalisées dans les années suivantes ont permis, grâce au recul, d'actualiser les chiffres. Nous aurions pu l'expliquer par le fait que le typage R pour les réfugiés a été ajouté à partir de UN_2017 mais il l'est pour toutes les autres sources internes.

Cas du couple Brésil – France métropolitaine et Brésil - Guyane


De plus, nous avons étudié le cas atypique de la migration du Brésil vers la France. En effet, nous avons étudié ce cas de deux manières différentes : dans un premier temps, nous avons analysé la migration du Brésil vers la France puis dans un deuxième temps, nous avons étudié la migration du Brésil vers la Guyane française, qui est une région d'outre-mer située sur la côte nord-est de l'Amérique du Sud, située à environ 2000 kilomètres du Brésil. Regarder ce cas en deux temps permet d'observer si les sources prennent en compte ou non les données des stocks concernant la Guyane française dans les données des stocks de la France métropolitaine.

Nous avons représenté graphiquement les stocks des migrations internationales avec comme pays de départ le Brésil et comme pays d'arrivée la France métropolitaine, en fonction des années de la période 1990-2020.



Par lecture graphique, nous constatons qu'il y a une différence de stocks entre 2010 et 2020 entre les différentes sources internes mais également un stock identique de 1990 à 2005, avec le même typage des données dans les 4 sources internes, qui prend en compte le pays de naissance.

Également, nous avons représenté graphiquement les stocks des migrations internationales avec comme pays de départ le Brésil et comme région d'arrivée la Guyane, en fonction des années de la période 1990-2020.



Par lecture graphique, nous constatons qu'il y a une différence de stocks entre 2015 et 2020 entre les différentes sources internes mais également un stock identique de 1990 à 2010, avec un typage des données différent entre la source interne UN_2020 qui prend en compte le pays de naissance et le statut de réfugié et les autres sources internes UN_2015, UN_2017 et UN_2019, qui prennent en compte uniquement le pays de naissance.


3. Analyse intra-sources (EU)

Concernant le producteur Eurostat, nous possédons seulement une source interne donc il est impossible d'y observer des écarts de stocks entre plusieurs sources. Donc nous analysons les données des stocks de migrants internationaux du producteur Eurostat que dans les analyses inter-sources.

4. Analyse intra-sources (OECD)

Cas du couple Syrie - Turquie


Dans cette analyse intra-source pour le producteur OECD, nous avons étudié le cas de conflit : Syriens en Turquie. Graphiquement, cela donne :



Par lecture graphique, nous observons une différence de stocks entre les sources DIOC et DIOC-E sur l'année 2010.

Cas du couple Brésil - France métropolitaine et Brésil - Guyane

Ensuite, nous avons représenté graphiquement le cas des territoires d'Outre-Mer pour observer les stocks entre le Brésil et la France, et entre le Brésil et la Guyane.



Par lecture graphique, nous constatons un écart de stock entre les trois sources internes en 2010 et un écart de stock entre la source OECD et DIOC en 2020.

Au sein de la base unique OECD, nous ne retrouvons des données de stocks avec comme pays de départ, le Brésil et comme pays d'arrivée, la Guyane, car les données de stocks de la Guyane sont intégrées aux données de stocks de la France métropolitaine.

5. Fusion des (UN, WB, EU, OECD)

Après avoir assemblé toutes les bases par producteur, nous avons fusionné les bases uniques des 4 producteurs pour obtenir une seule base unique que nous avons appelé ABIMS sous un fichier Excel, que nous avons importé dans le logiciel R-Studio pour effectuer des analyses statistiques sur cette nouvelle base unique.

Cette nouvelle base est constituée de plusieurs variables :

Variables	Modalités	Label
year	1960 à 2023	Année du stock migratoire
from	Codes ISO3 des pays issus du package Country Code	Pays d'origine
to	Codes ISO3 des pays issus du package Country Code	Pays de destination
value	[0 ; +∞)	Stock de migrants internationaux
source	- OECD, DIOC, DIOC-E - UN_2015, UN_2017, UN_2019, UN_2020 - Eurostat - WDR_2023, WB_GMDB, WB_Kd	Sources de données issues du recensement de la population la plupart du temps
country_born	- 1 : si le typage des données correspond à country_born - 0 : sinon	Indicatrice du pays de naissance
Nationality	- 1 : si le typage des données correspond à Nationality - 0 : sinon	Indicatrice de la nationalité
Refugee	- 1 : si le typage des données correspond à Refugee - 0 : sinon	Indicatrice du statut de réfugié
Imputation	- 1 : si le typage des données correspond à Imputation - 0 : sinon	Indicatrice des données imputées

Tableau 1 : Tableau des variables avec leurs modalités et leurs labels


Pour les analyses inter-sources, nous avons privilégié la source la plus récente de chaque producteur car il est plus pertinent d'avoir des données actualisées plus récemment, d'avoir une meilleure comparabilité entre les pays. Néanmoins ces données de stocks de migrants ont pu être modifiées par des événements comme la pandémie de Covid-19, qui a affecté les déplacements internationaux. Donc disposer des données les plus récentes permet d'obtenir des estimations plus précises.

6. Analyse inter-sources après fusion

Nous avons effectué une analyse inter-source sur des cas de conflits et des cas de territoires d'Outre-Mer que nous avons déjà analysé au niveau intra.

Cas du couple Syrie - Turquie


En ce qui concerne le cas de conflit qui concerne les Syriens en Turquie, nous avons représenté graphiquement les stocks des migrants internationaux en fonction des années, avec comme pays de départ la Syrie et comme pays de destination la Turquie, en privilégiant la source la plus récente de chaque producteur, ci-dessous :



Par lecture graphique, nous observons une différence de stock, entre les sources Eurostat et OECD à partir de 1990, entre les sources UN_2020 et OECD à partir de 2015, entre les quatre sources en 2020.

Cas du couple Brésil - France métropolitaine et Brésil - Guyane

En ce qui concerne le cas des territoires d'Outre-Mer où l'on a étudié le stock de migrants du Brésil vers la France métropolitaine, graphiquement, ci-dessous :



Par lecture graphique, nous constatons des écarts de stocks entre les sources, notamment sur les années 2000, 2010 et 2020, mais avec des allures de courbes qui ont presque la même trajectoire. En revanche, nous ne possédons pas les données de plusieurs sources en prenant la Guyane comme pays de destination.

III. Traitement de données

1. Identifier et analyser les observations aberrantes


Méthode 1 : Calcul du Z-Score

Pour identifier et analyser les observations aberrantes, nous avons fait le choix d'utiliser une première méthode qui s'appelle la méthode statistique du Z-score. Nous utiliserions la méthode statistique du Z-score qui est une mesure standardisée qui indique combien d'écarts-types une valeur de stock est éloignée de la moyenne. Elle repose sur des propriétés de la loi normale où :

68,2 % des données sont dans l'intervalle $[\mu - 1\sigma, \mu + 1\sigma]$

95,4 % des données sont dans l'intervalle $[\mu - 2\sigma, \mu + 2\sigma]$

99,7 % des données sont dans l'intervalle $[\mu - 3\sigma, \mu + 3\sigma]$



Donc à partir de là, si la valeur du stock a un $|Z\text{-score}| > 3$, cela veut dire que cette valeur se situera à l'extérieur des 99,7% des observations normales. Ainsi, elle se retrouverait très loin de la moyenne de la distribution normale donc elle serait une valeur aberrante.

Nous avons calculé le Z-score qui est défini par la formule suivante :

$$Z = \frac{X - \mu}{\sigma}$$

Où :

Z est le score standardisé

X est le stock de migrants internationaux

μ est la moyenne des stocks sur tout l'échantillon

σ est l'écart-type des stocks sur tout l'échantillon

Z-Score

Pour toutes notre analyse inter-source, nous avons restreint l'échelle de la période des années en étudiant les stocks par couples de pays entre 1990 et 2020.

Nous avons calculé la moyenne et l'écart-type spécifiquement pour chaque couple de pays (c'est-à-dire en fonction des colonnes from et to), nous avons utilisé la fonction `group_by()` pour calculer ces valeurs par groupe (par couple de pays), puis nous avons appliqué la formule du Z-score sur chaque groupe individuellement. Nous avons obtenu une base de données qui regroupe toutes les valeurs de stock normales et aberrantes, dont nous avons représenté une partie ci-dessous :

year	from	to	value	source	country_born	Nationality	Refugee	Imputation	mean_stock	sd_stock	z_score
2014	AND	ITA	128.000	OECD	1	0	0	0	51.473684	24.3418634	3.14381502
2015	AND	ITA	106.000	OECD	1	0	0	0	51.473684	24.3418634	2.24002225
2016	AND	ITA	53.000	OECD	1	0	0	0	51.473684	24.3418634	0.06270333
2017	AND	ITA	54.000	OECD	1	0	0	0	51.473684	24.3418634	0.10378481
2018	AND	ITA	44.000	OECD	1	0	0	0	51.473684	24.3418634	-0.30703008
2019	AND	ITA	44.000	OECD	1	0	0	0	51.473684	24.3418634	-0.30703008
2020	AND	ITA	46.000	OECD	1	0	0	0	51.473684	24.3418634	-0.22486710
2017	AND	JPN	3.000	OECD	0	1	0	0	3.000000	0.8164966	0.00000000
2018	AND	JPN	4.000	OECD	0	1	0	0	3.000000	0.8164966	1.22474487
2019	AND	JPN	2.000	OECD	0	1	0	0	3.000000	0.8164966	-1.22474487
2020	AND	JPN	3.000	OECD	0	1	0	0	3.000000	0.8164966	0.00000000
2012	AND	KOR	1.000	OECD	0	1	0	0	1.666667	1.1547005	-0.57735027
2019	AND	KOR	3.000	OECD	0	1	0	0	1.666667	1.1547005	1.15470054
2020	AND	KOR	1.000	OECD	0	1	0	0	1.666667	1.1547005	-0.57735027

Dans cette base, nous avons les variables : mean_stock (Moyenne des stocks pour chaque couple de pays), sd_stock (Écart-type des stocks pour chaque couple de pays) et z_score (Z-Score de la variable value (le stock de migrant) pour chaque couple de pays).

Nous pouvons récapituler dans un tableau les couples de pays, analysés précédemment en indiquant si leurs Z-Score est tel que $|Z\text{-score}| > 3$:

Couples de pays	$ Z\text{-Score} > 3$
Syrie-Turquie	Non
Brésil-France métropolitaine	Non
Brésil-Guyane	Non
Nigéria-Allemagne	Oui - Année : 2020 Source : Eurostat

Concernant le couple Syrie-Turquie, nous n'avons pas trouvé de valeurs aberrantes dans ces observations malgré que l'observation qui possède un Z-Score le plus élevé tel que $|Z\text{-score}| > 3$, correspond au stock de l'année 2020 de la source UN_2020 où $|Z\text{-score}| = 2.7016589 \approx 3$.

Concernant le couple Nigéria-Allemagne, nous avons repéré 1 valeur aberrante sur l'année 2020 de la source Eurostat donc on peut considérer que cette valeur est anormale dû au fait que le typage utilisé est celui de la nationalité tandis que les observations de la source la plus récente des trois autres producteurs sur la même année ont comme typage utilisé, le pays de naissance.

Méthode 2 : Calcul des écarts

L'objectif de cette étude est d'examiner les écarts entre différentes sources de données concernant les flux migratoires entre une paire de pays donnée. L'objectif principal est d'identifier les incohérences et de repérer d'éventuelles possibilités de valeurs aberrantes à travers des visualisations telles que les boxplots.

En comparant les estimations issues de différentes sources, nous pouvons déterminer dans quelle mesure elles convergent ou divergent. Un écart important indique une divergence significative entre les sources, tandis qu'un écart faible suggère une cohérence entre les estimations.

Prenons l'exemple des flux migratoires entre **les Comores et la France**.

L'analyse repose sur plusieurs étapes :


1. Calcul des écarts entre les estimations fournies par différentes sources pour chaque paire de pays. Cela nous permet de quantifier les différences.
2. Construction d'un tableau récapitulatif des écarts pour faciliter l'interprétation des résultats.

year <dbl>	WDR_2023 - UN_2020 <dbl>	WDR_2023 - OECD <dbl>	UN_2020 - Eurostat <dbl>	UN_2020 - OECD <dbl>
1960	NA	NA	NA	NA
1970	NA	NA	NA	NA
1980	NA	NA	NA	NA
1990	3479	NA	NA	NA
1995	NA	NA	NA	NA
1999	NA	NA	NA	NA
2000	37712	43790	NA	6078
2005	NA	NA	190	NA
2006	NA	NA	NA	NA
2007	NA	NA	NA	NA


1-10 of 24 rows | 1-5 of 6 columns

Previous 1 2 3 Next

3. Visualisation des écarts sous forme de boxplots, afin d'identifier graphiquement les valeurs aberrantes.



4. Détection des valeurs aberrantes, qui correspondent aux écarts les plus extrêmes entre les sources. Ces valeurs traduisent une forte divergence dans les estimations de stocks migratoires.
5. Vérification des données à travers la superposition des courbes des différentes sources pour mieux comprendre l'origine des écarts.



Grâce aux **boxplots**, nous pouvons rapidement identifier les **valeurs aberrantes**, qui apparaissent sous forme de points isolés en dehors des limites normales. Ces valeurs indiquent une grande différence entre les estimations des sources, ce qui peut être dû à :

- Des différences de méthodologie entre les sources de données.
- Des erreurs de collecte ou de mise à jour des données.

- Une variabilité intrinsèque liée aux estimations des stocks migratoires.
-

Methode 3 : Calcul du Z-Score et l'intervalle interquartile

L'objectif de cette analyse est d'identifier les valeurs aberrantes dans les bases de données de migration provenant de différentes organisations : OCDE, Eurostat, Banque Mondiale et Nations Unies. Nous avons appliqué deux méthodes statistiques, le Z-score et l'intervalle interquartile (IQR), pour détecter les anomalies. Une colonne detected_outlier a été ajoutée pour signaler la présence d'une valeur aberrante (Oui) ou non (Non).

Méthodologie et Filtrage des Données

- Définition des analyses :
 - Analyse intra-source : nous comparons les valeurs provenant d'une même source (ex. Nations Unies) pour identifier les incohérences internes.
 - Analyse inter-source : nous comparons les valeurs issues de différentes organisations (ex. OCDE vs Eurostat vs Banque Mondiale vs Nations Unies).
- Condition de sélection des données :
 - Les stocks d'immigration (value) sont étudiés à l'échelle globale, sans se limiter à un seul couple de pays ou une seule année.
 - Minimum de 3 valeurs par année et par organisme pour assurer la robustesse des comparaisons intra-source.

year	from	to	value	type	source	zscore_flag	iqr_flag	detected_outlier
2010	MEX	USA	11566960	B	UN_2015	Normal	Outlier	Oui
2005	MEX	USA	10309054	B	UN_2015	Normal	Outlier	Oui
2000	MEX	USA	9177487	B	UN_2015	Normal	Outlier	Oui
1995	MEX	USA	6602801	B	UN_2015	Normal	Outlier	Oui
1990	AFG	IRN	3980307	C R	UN_2020	Normal	Outlier	Oui
2015	IND	ARE	3499337	C R	UN_2015	Normal	Outlier	Oui
2005	BGD	IND	3298833	B R	UN_2020	Normal	Outlier	Oui
2010	BGD	IND	2855334	B R	UN_2020	Normal	Outlier	Oui

Résultats

Analyse Intra-Source :

Les valeurs aberrantes ont été principalement observées dans la base des Nations Unies (UN_2020), suggérant des problèmes internes de collecte ou d'imputation des données. Les autres bases (OCDE, Eurostat, Banque Mondiale) n'ont pas montré de valeurs aberrantes après application du filtre de 3 sources minimales.

Analyse Inter-Source :

Les Nations Unies ont présenté davantage de valeurs aberrantes que les autres sources (OCDE, Eurostat, Banque Mondiale), ce qui indique une plus grande variabilité dans les données de cette organisation.




Figure: Inter-source ABIMS



Figure: Intra-source de la table UN

Types de données impactées :

Les types de données concernant la population née à l'étranger (B) et les pays de naissances (**Birth_Country**) étaient les plus affectés par les valeurs aberrantes, probablement en raison de la diversité des contextes migratoires.

Type	Non	Oui
B	16954	2224
B R	721	2
Birth_Country	10066	260
C	703	134
C R	146	0
Citizenship	1432	38
Country of birth	8550	190

Tableau : Croisement des Nb de valeurs aberrants avec le typage des données dans la inter-sources

Efficacité des méthodes :

Les méthodes de détection des valeurs aberrantes, telles que le **Score Z** et l'**Intervalle Interquartile**, ont montré une efficacité limitée. Elles n'ont pas détecté de nombreuses anomalies, surtout à cause des données peu variées et aussi notre méthodologie de filtre.

Discontinuité des données :

La discontinuité des données entre les années a constitué un obstacle majeur à l'analyse. L'absence de données pour certaines années a limité la détection d'anomalies.

IV. Conclusion

Au cours de ce projet, l'objectif principal était d'analyser les données de migration en utilisant des méthodes statistiques pour détecter les valeurs aberrantes, à la fois intra-sources et inter-sources, provenant de différentes bases de données internationales telles que la Banque mondiale (WB), les Nations Unies (UN), Eurostat et l'OCDE. Plusieurs observations et résultats importants ont émergé.

Cependant, l'interprétation de ces anomalies reste complexe. En effet, plusieurs facteurs peuvent expliquer ces écarts, tels que des **problèmes de discontinuité des données** d'année en année sur les recensements de différents pays, **l'agrégation des pays** (comme celle de la France et des territoires d'outre-mer), ainsi que des **conflits** géopolitiques (notamment en Syrie) qui ont perturbé les données migratoires. De plus, la difficulté à standardiser les données sur toutes les années a limité la possibilité de tirer des conclusions précises quant à la cause des valeurs aberrantes. En somme, bien que des anomalies aient été détectées, il n'a pas été possible de les associer de manière fiable à des événements spécifiques, comme des conflits ou des crises, en raison des lacunes dans les données et des différentes méthodes de collecte.

V. Bibliographie

<https://www.un.org/fr/about-us>

<https://www.un.org/development/desa/pd/content/international-migrant-stock>

<https://www.worldbank.org/en/about/leadership>

<https://ec.europa.eu/eurostat/fr/about-us/who-we-are>

<https://www.oecd.org/fr.html>

<https://data-explorer.oecd.org/>

<https://perspective.usherbrooke.ca/bilan/servlet/BMAAnalyse/2670>

<https://www.histoirealacarte.com/Europe-depuis-1945/les-guerres-dans-lex-yougoslavie>

https://www.touteleurope.eu/le-glossaire-de-l-europe/eurostat/*

<https://www.oecd.org/fr/about.html>

Ozden, C., Parsons, C. R., Schiff, M., Walmsley, T. L., The Author, United Nations Population Division, United Nations Statistics Division, World Bank, University of Sussex, United Nations, United States Census Bureau, Max Planck Institute for the Study of Religious and Ethnic Diversity, & World Bank Knowledge for Change Program. (2011). Where on Earth is Everybody? The Evolution of Global Bilateral Migration 1960–2000. In *THE WORLD BANK ECONOMIC REVIEW* (Vols. 25–25, Issue 1, pp. 12–56).

<https://doi.org/10.1093/wber/lhr024>