
Rapport Business Intelligence

Analyse RFM · Gestion des Risques · Cost-Down

École HETIC — Cours Business Intelligence

Date	22 mars 2026
Outils	Python · Power BI · Power Query · DAX
Participants :	Lina Benzemma Oumar Cissé Arezki Hassak Bruno Tagaigne Beni Nzongo

Table des matières

1	Hypothèses sur la provenance et la collecte des données	3
1.1	Section RFM — customers, transactions, marketing	3
1.1.1	customers.csv — 80 000 clients	3
1.1.2	transactions.csv — 2 000 000 lignes	3
1.1.3	marketing.csv — 200 campagnes	3
1.2	Section Gestion des Risques — inventory, products, warehouses	3
1.2.1	inventory.csv — Table des stocks	3
1.2.2	products.csv — Référentiel produits	3
1.2.3	warehouses.csv — Référentiel entrepôts	3
1.3	Section Cost-Down — warehouses, accounting, logistics	4
1.3.1	accounting.csv — Données comptables	4
1.3.2	logistics.csv — Données de transport	4
1.3.3	Synthèse des hypothèses	4
2	Collecte des données	4
3	Rapport d’audit des données	5
3.1	customers.csv — 80 000 lignes	5
3.2	marketing.csv — 200 lignes	5
3.3	transactions.csv — 2 000 000 lignes	5
3.4	inventory.csv (Gestion des risques)	6
3.5	warehouses / accounting / logistics (Cost-Down)	6
4	Section RFM — Analyse Marketing	7
4.1	Stack technique	7
4.2	Rapport ETL — Nettoyage des données	7
4.2.1	customers.csv — 80 000 clients	7
4.2.2	marketing.csv — 200 campagnes	7
4.2.3	transactions.csv — 2 000 000 lignes	8
4.3	Grain, tables de fait et dimensions	8
4.3.1	Définition du grain	8
4.3.2	Tables de fait et dimensions	8
4.4	Schéma relationnel	9
4.5	Mesures DAX	9
4.6	Dashboards et interprétation	9
4.6.1	Dashboard 1 — Performances clients et KPIs	10
4.6.2	Dashboard 2 — CA par fidélité, canaux et genre	11
4.6.3	Dashboard 3 — Segmentation RFM	12
4.7	BI descriptive et call to action	12
5	Section Gestion des Risques de Stock	13
5.1	Stack technique	13
5.2	Rapport ETL — Nettoyage et transformations	13
5.2.1	Objectif du processus ETL	13
5.2.2	Nettoyage des données	13

5.2.3	Transformations réalisées	13
5.2.4	Audit détaillé par fichier	14
5.2.5	Mesures DAX créées	15
5.3	Grain, tables de fait et dimensions	15
5.3.1	Définition du grain	15
5.3.2	Table de fait — inventory	15
5.3.3	Tables de dimensions	16
5.3.4	Lien avec les objectifs du projet	16
5.4	Schéma relationnel	17
5.5	Dashboards et interprétation	17
5.5.1	Dashboard 1 — Synthèse stock et KPIs	18
5.5.2	Dashboard 2 — Analyse détaillée des risques	19
5.5.3	Dashboard 3 — Top 10 produits critiques	20
5.6	BI descriptive et call to action	20
6	Section Cost-Down — Réduction des Coûts	21
6.1	Stack technique	21
6.2	Rapport ETL — Nettoyage et transformations	21
6.2.1	Synthèse globale des fichiers traités	21
6.2.2	Opérations de nettoyage réalisées	22
6.2.3	Calculs et indicateurs créés	22
6.3	Grain, tables de fait et dimensions	22
6.3.1	Définition des grains	22
6.3.2	Tables de dimensions	23
6.3.3	Mesures DAX	23
6.4	Schéma relationnel	24
6.5	Dashboards et interprétation	24
6.5.1	Dashboard 1 — Synthèse exécutive Cost-Down	25
6.5.2	Dashboard 2 — Entrepôts & Énergie	26
6.5.3	Dashboard 3 — Logistique (Carburant & CO ₂)	27
6.6	BI descriptive au call to action	27

Hypothèses sur la provenance et la collecte des données

Dans le cadre de ce projet Business Intelligence, les données ont été fournies sous forme de fichiers CSV représentant le contexte opérationnel de Carrefour. En l'absence de documentation technique sur leur origine exacte, cette section formule des **hypothèses vraisemblables** sur la provenance et les modalités de collecte de chaque fichier, en s'appuyant sur les pratiques simulées dans un contexte réaliste d'un grand groupe de distribution.

Note : Il s'agit ici de suppositions formulées dans un cadre académique. Nous supposons que ces données sont issues de Carrefour, sans que cela soit avéré. Les hypothèses sur les systèmes sources (CRM, WMS, ERP, TMS...) sont cohérentes avec l'organisation d'un grand groupe retail, et permettent d'ancrer l'analyse dans un contexte métier réaliste.

Section RFM — customers, transactions, marketing

customers.csv — 80 000 clients

Provenance : Ces données sont issues du **CRM** (Customer Relationship Management) de l'enseigne, alimenté lors de la création des cartes de fidélité en caisse ou en ligne.

transactions.csv — 2 000 000 lignes

Provenance : Ces données sont issues du **système de caisse** (POS — Point of Sale) et de la **plateforme e-commerce**, exportées quotidiennement vers un entrepôt de données central.

marketing.csv — 200 campagnes

Provenance : Ces données proviennent de la **plateforme de gestion des campagnes marketing** (type Salesforce Marketing Cloud ou outil interne), alimentée par les équipes trade marketing.

Section Gestion des Risques — inventory, products, warehouses

inventory.csv — Table des stocks

Provenance : Ces données sont issues du **WMS** (Warehouse Management System), qui enregistre les niveaux de stock à intervalle régulier (snapshot journalier ou hebdomadaire).

products.csv — Référentiel produits

Provenance : Ces données sont issues du **PIM** (Product Information Management), le référentiel central des produits, alimenté par les équipes achat et les fournisseurs.

warehouses.csv — Référentiel entrepôts

Provenance : Ces données sont issues du **système de gestion immobilière et logistique**, tenu à jour par la direction des opérations.

Section Cost-Down — warehouses, accounting, logistics

accounting.csv — Données comptables

Provenance : Ces données proviennent de l'**ERP** (Enterprise Resource Planning, type SAP), qui centralise toutes les dépenses de l'entreprise par centre de coûts.

logistics.csv — Données de transport

Provenance : Ces données sont issues du **TMS** (Transport Management System), alimenté par les capteurs GPS des camions et les bordereaux de livraison électroniques.

Synthèse des hypothèses

Fichier	Système source supposé	Mode de collecte
customers	CRM	Inscription carte fidélité (caisse / web)
transactions	POS + e-commerce	Enregistrement automatique en caisse
marketing	Plateforme CRM	Saisie manuelle équipes marketing
inventory	WMS	Snapshot journalier automatique
products	PIM	Référencement par les acheteurs
warehouses	Gestion immobilière	Saisie mensuelle + compteurs énergie
accounting	ERP (SAP)	Saisie notes de frais + validation
logistics	TMS + GPS	Télématique embarquée + saisie chauffeur

Remarque : Les anomalies détectées lors du nettoyage (valeurs aberrantes, BA-DID, identifiants inconnus...) sont représentatives des problèmes couramment rencontrés dans les exports de systèmes d'information d'un grand groupe de distribution. Elles résultent de la multiplicité des systèmes sources, des saisies manuelles et de l'absence de contrôles systématiques à l'entrée des données.

Collecte des données

Les données utilisées dans ce projet sont des fichiers CSV fournis en entrée. Aucune API ni flux temps réel n'a été mobilisé. La collecte et le traitement ont été réalisés avec les technologies suivantes :

Technologie	Usage
Python / pandas	Nettoyage, transformation et audit des données (ETL)
Power Query	ETL complémentaire dans Power BI Desktop
Power BI en ligne	Modélisation, relations entre tables et visualisation
Power BI Desktop	Modélisation avancée (Cost-Down, Gestion des risques)
DAX	Calcul des mesures et indicateurs analytiques
CSV	Format de stockage des données sources et nettoyées

Rapport d'audit des données

customers.csv — 80 000 lignes

Colonne	Anomalies	%	Nature du problème
gender	2 264	2,8%	Valeurs "Narnia", "extra", "inconnu"
loyalty_status	2 227	2,8%	Valeurs "Narnia", "extra", "inconnu"
country	2 292	2,9%	Valeurs "Narnia", "extra", "inconnu"
acquisition_source	2 251	2,8%	Valeurs "Narnia", "extra", "inconnu"
birth_date	2 924	3,7%	Âge incohérent (<16 ans ou >110 ans)
Total doublons	0	—	—
Lignes finales	80 000	—	Aucune ligne supprimée

marketing.csv — 200 lignes

Colonne	Anomalies	%	Nature du problème
promotion_type	13	6,5%	Valeurs "Narnia", "extra", "inconnu"
target_customer_type	5	2,5%	Valeurs "inconnu"
discount_value	16	8,0%	Valeurs négatives
product_segment	23	11,5%	Valeurs manquantes
channel	9	4,5%	Valeurs manquantes
Total doublons	0	—	—
Lignes finales	200	—	Aucune ligne supprimée

transactions.csv — 2 000 000 lignes

Colonne	Anomalies	%	Nature du problème
customer_id	163 305	8,2%	Valeur UNKNOWN
product_id	163 773	8,2%	Valeur UNKNOWN
store_id	163 172	8,2%	Valeur UNKNOWN
sales_channel	146 722	7,3%	Valeur aberrante "extra"
total_price	199 564	10,0%	Prix = 0 avec quantité > 0
total_price (négatif)	66 240	3,3%	Prix négatifs
actual_delivery_date	66 726	3,3%	Date antérieure à l'achat
Doublons supprimés	67 598	3,4%	Sur transaction_id
Sans customer_id	149 274	7,5%	Inutilisables pour le RFM
Lignes finales propres	1 783 128	—	—

inventory.csv (Gestion des risques)

Colonne	Anomalies	%	Nature du problème
expired_quantity	plusieurs	—	Valeurs nulles remplacées par 0
inventory_id	présents	—	Doublons supprimés
IDs invalides	présents	—	Filtrage des identifiants aberrants
Types	—	—	Conversions date, numérique, texte

warehouses / accounting / logistics (Cost-Down)

Fichier	Problèmes détectés	Traitement
warehouses	Schémas non normalisés, types incorrects	Minuscules, trim, conversion surface_sqm, calcul Énergie/m ²
accounting	Centres de coûts invalides (NON_RENSEIGNE, inconnu, Narnia), receipt non booléen	Normalisation booléen, marquage centres douteux
logistics	ENT_UNKNOWN, BADID, types incorrects	Conversion km, litres, CO ₂ , calcul L/100km, Shrinkage %

Section RFM — Analyse Marketing

Stack technique

Outil	Rôle
Python (pandas)	Nettoyage et transformation des données (ETL)
Fichiers CSV	Stockage des données sources et nettoyées
Power BI en ligne	Modélisation, relations entre tables et visualisation
DAX	Calcul des indicateurs RFM et segmentation

Rapport ETL — Nettoyage des données

customers.csv — 80 000 clients

Colonne	Anomalies	%	Nature
gender	2 264	2,8%	Valeurs "Narnia", "extra", "inconnu"
loyalty_status	2 227	2,8%	Valeurs "Narnia", "extra", "inconnu"
country	2 292	2,9%	Valeurs "Narnia", "extra", "inconnu"
acquisition_source	2 251	2,8%	Valeurs "Narnia", "extra", "inconnu"
birth_date	2 924	3,7%	Âge incohérent (<16 ou >110 ans)
Doublons	0	—	—
Résultat	80 000 lignes	—	Propres

marketing.csv — 200 campagnes

Colonne	Anomalies	%	Nature
promotion_type	13	6,5%	Valeurs aberrantes supprimées
target_customer_type	5	2,5%	Valeurs "inconnu"
discount_value	16	8,0%	Valeurs négatives → valeur absolue
product_segment	23	11,5%	Valeurs manquantes
Résultat	200 lignes	—	Propres

transactions.csv — 2 000 000 lignes

Colonne	Anomalies	%	Nature
customer_id	163 305	8,2%	UNKNOWN → NaN
product_id	163 773	8,2%	UNKNOWN → NaN
sales_channel	146 722	7,3%	Valeur "extra" supprimée
total_price	199 564	10,0%	Prix = 0 avec quantité > 0
total_price (négatif)	66 240	3,3%	→ valeur absolue
Doublons	67 598	3,4%	Supprimés sur transaction_id
Sans customer_id	149 274	7,5%	Supprimés (inutilisables RFM)
Résultat	1 783 128 lignes	—	Propres

Grain, tables de fait et dimensions

Définition du grain

1 ligne = 1 article acheté par 1 client à 1 moment précis
transaction individuelle · canal de vente · mode de paiement

Tables de fait et dimensions

Table	Type	Lien avec les objectifs
FACT_transactions	Fait	Calcul de Récence, Fréquence, Montant (RFM)
DIM_customers	Dimension	Identifier et segmenter les clients
DIM_marketing	Dimension	Analyser l'impact des campagnes marketing
Date	Dimension	Analyser les tendances temporelles

Schéma relationnel




FIGURE 1 – Schéma relationnel — Power BI

Les relations du modèle en étoile :

- DIM_customers → FACT_transactions via **customer_id** (1 à N)
- DIM_marketing → FACT_transactions via **product_id** (1 à N)
- Date → FACT_transactions via **date** (1 à N)

Mesures DAX

Mesure	Description
Récence	Nombre de jours depuis le dernier achat
Fréquence	Nombre de transactions par client
Montant_Total	Somme du chiffre d'affaires par client
Score_R/F/M	Notation de 1 à 5 par dimension
Segment_RFM	Champions · Fidèles · À risque · Perdus · Nouveaux

Dashboards et interprétation

Dashboard 1 — Performances clients et KPIs




FIGURE 2 – Dashboard — Performances clients et commerciales (partie 1)

Interprétation : Le dashboard affiche 4 KPIs clés : 77 020 clients, 175,97M€ de chiffre d'affaires total, 2 millions de transactions et un panier moyen de 2 280€. La répartition par fidélité montre que les clients *bronze* sont les plus nombreux (29 800), suivis des *argent* (22 200). Concernant le canal d'acquisition, le web domine avec 60,15% des clients (44 860), ce qui suggère une forte présence digitale à entretenir.

Dashboard 2 — CA par fidélité, canaux et genre




FIGURE 3 – Dashboard — Performances clients et commerciales (partie 2)

Interprétation : Les clients *bronze* génèrent le CA le plus élevé (61M€) malgré leur statut de fidélité le plus bas, ce qui révèle un fort potentiel de fidélisation inexploité. Le canal *en magasin* domine avec 112M€ vs 52M€ en ligne. Le CA montre une baisse en 2025 (14 349K) après un pic en 2024 (14 474K), signal d’alerte nécessitant une action marketing ciblée. La répartition par genre est quasi-équilibrée (50/50).

Dashboard 3 — Segmentation RFM




FIGURE 4 – Dashboard — Segmentation clients selon leur valeur RFM

Interprétation : La segmentation RFM révèle une situation préoccupante : **76 834 clients sont à risque**, soit la grande majorité de la base. Seulement 2 784 champions et 18 444 clients fidèles constituent le noyau dur rentable. Le nombre de nouveaux clients (3) et de clients réguliers (177) est extrêmement faible, signe d’un déficit d’acquisition et de rétention à corriger en priorité.

BI descriptive et call to action

La BI descriptive répond à la question : « *Que s’est-il passé ?* ». En analysant les données historiques, on observe les tendances ci-dessus. Les actions à mener par segment sont les suivantes :

Segment	Action recommandée	Priorité
Champions (2 784)	Programme VIP, offres exclusives, avant-premières	Haute
Clients fidèles (18 444)	Upsell, carte de fidélité, parrainage	Haute
À risque (76 834)	Email de réactivation, promotion ciblée	Urgente
Clients perdus (7)	Campagne win-back avec remise forte	Urgente
Nouveaux clients (3)	Onboarding, offre de bienvenue	Moyenne

Section Gestion des Risques de Stock

Stack technique

Outil	Rôle
Power BI Desktop	Modélisation et visualisation interactive
Power Query	ETL — nettoyage et transformation des données
DAX	Calcul des indicateurs de risque et mesures analytiques

Rapport ETL — Nettoyage et transformations

Objectif du processus ETL

Le processus ETL vise à préparer les données afin de garantir leur qualité, leur cohérence et leur exploitabilité pour l'analyse du stock et des risques de rupture dans Power BI.

Nettoyage des données

Action	Description	Objectif
Gestion des valeurs nulles	Remplacement des valeurs nulles (ex : <code>expired_quantity</code>)	Éviter les erreurs de calcul
Suppression des doublons	Suppression basée sur <code>inventory_id</code>	Garantir l'unicité des enregistrements
Suppression valeurs incohérentes	Filtrage des ID invalides et données aberrantes	Améliorer la qualité des données
Correction des types	Conversion des types (date, numérique, texte)	Assurer la cohérence du modèle

Transformations réalisées

Colonne créée	Description	Objectif métier
<code>location_id</code>	Fusion de <code>warehouse_id</code> et <code>store_warehouse_id</code>	Uniformiser la localisation
<code>stock_status</code>	Risque de rupture ou Stock suffisant	Identifier les produits critiques
Table Date	Création calendrier (année, mois, trimestre)	Analyse temporelle

Audit détaillé par fichier

Cette section présente les anomalies identifiées dans chaque table utilisée pour l'analyse des risques de rupture, ainsi que les traitements appliqués.

inventory.csv — Table principale (stock)

Colonne	Niveau	Nature du problème	Traitement
stock_quantity	Faible	Valeurs négatives ou incohérentes	Remplacement par 0
alert_threshold	Faible-moderé	Valeurs nulles	Imputation
expired_quantity	Faible	Incohérences (supérieur au stock)	Correction
product_id	Moderé	Valeurs inconnues (UNKNOWN)	Nettoyage / suppression
location_id	Faible	Valeurs manquantes	Filtrage

products.csv — Table dimension produit

Colonne	Niveau	Nature du problème	Traitement
category	Faible	Valeurs incohérentes	Regroupement
co2_per_kg	Faible-moderé	Valeurs nulles	Imputation
expiry_date	Faible	Incohérences	Correction
margin_rate	Faible	Valeurs aberrantes	Normalisation

warehouses.csv — Table dimension entrepôt

Colonne	Niveau	Nature du problème	Traitement
occupancy_rate	Faible	Valeurs > 100%	Plafonnement à 100%
storage_capacity	Faible	Valeurs nulles	Remplacement
city	Faible	Incohérences	Normalisation

Date — Table calendrier

Transformation	Objectif
Extraction année, mois, trimestre	Analyse temporelle
Création colonne Année-Mois	Visualisation
Structuration du calendrier	Cohérence des analyses

Les anomalies observées restent globalement faibles et ont été traitées afin de garantir la fiabilité des indicateurs, notamment dans l'identification des risques de rupture.

Mesures DAX créées

Mesure	Description	Objectif
Stock Total	Somme des quantités en stock	Vue globale du stock
Stock Moyen	Moyenne des quantités	Analyse de tendance
Produits à risque	Nombre de produits sous le seuil	Identifier les risques
Taux de rupture	Produits à risque / total produits	Mesurer la criticité
Score Risque	Écart entre le seuil et le stock réel	Prioriser les actions

Grain, tables de fait et dimensions

Définition du grain

1 ligne = 1 observation du stock d'un produit, dans une localisation donnée, à une date donnée

produit · entrepôt ou magasin · date · quantité de stock associée

Ce niveau de granularité permet une analyse précise du stock et des risques de rupture.

Table de fait — inventory

La table de fait utilisée est la table `inventory`. Elle contient :

- **Mesures quantitatives** : `stock_quantity`, `alert_threshold`, `expired_quantity`
- **Clés étrangères** : `product_id`, `warehouse_id`, `store_warehouse_id`, `snapshot_date`

Cette table permet de répondre à la problématique principale : analyser le stock de produits et identifier les risques de rupture.

Tables de dimensions

Dimension	Contenu	Utilité analytique
Produit (products)	Nom, catégorie, caractéristiques, marge, CO ₂ /kg	Analyser le stock par produit, identifier les produits critiques, segmenter par catégorie
Entrepôt (warehouses)	Pays, type d'entrepôt, capacité, surface, coût énergie	Analyser la répartition géographique, évaluer la performance logistique
Entrepôts magasins (store_warehouses)	Infos relatives aux entrepôts associés aux magasins	Analyser le stock au niveau local, compléter la vision logistique
Temps (Date)	Année, mois, trimestre, jour, Année-Mois	Analyser l'évolution du stock dans le temps, identifier les périodes critiques

Lien avec les objectifs du projet

- **Suivre le niveau de stock dans le temps** grâce à la dimension Date
- **Identifier les produits à risque de rupture** grâce aux indicateurs calculés
- **Analyser la répartition du stock** par produit et par localisation
- **Optimiser la gestion logistique** à partir des analyses croisées

Schéma relationnel





FIGURE 5 – Schéma relationnel — Gestion des risques de stock (Power BI)

Les relations du modèle en étoile :

- **products** → **inventory** via **product_id** (1 à N)
- **warehouses** → **inventory** via **warehouse_id** (1 à N)
- **store_warehouses** → **inventory** via **store_warehouse_id** (1 à N)
- **Date** → **inventory** via **snapshot_date** (1 à N)

Dashboards et interprétation

Dashboard 1 — Synthèse stock et KPIs



Dashboard 2 — Analyse détaillée des risques




FIGURE 7 – Dashboard — Évolution des risques, répartition par pays et type d'entrepôt

Interprétation : L'évolution des produits à risque dans le temps révèle des pics à 5 produits en rupture simultanément en mai-septembre 2024. La répartition par niveau de risque montre que 99,62% du stock est suffisant (10,32M unités) mais les 0,38% en risque de rupture (0,04M) concernent des produits critiques à surveiller. Géographiquement, la **France concentre 46,21%** du stock (2,04M), suivie de l'Allemagne (21,17%). Par type d'entrepôt, les entrepôts *secs* dominent avec 2,44M unités, devant les *automatisés* (1,12M) et *réfrigérés* (0,97M).

Dashboard 3 — Top 10 produits critiques




FIGURE 8 – Dashboard — Top 10 des produits les plus critiques en risque de rupture

Interprétation : Le top 10 des produits critiques affiche des écarts au seuil très élevés, allant de 618 à **1 046 unités** sous le seuil d'alerte. Les deux produits les plus critiques ("*L'assurance d'avancer en toute tranquillité*" et "*L'avantage de concrétiser vos projets*") dépassent les 1 000 unités de déficit. Ces produits nécessitent un réapprovisionnement immédiat pour éviter une rupture de stock totale.

BI descriptive et call to action

Niveau BI	Application
Descriptif	Mesurer : stock total, taux de rupture 47,94%, top 10 produits critiques
Diagnostic	Expliquer : périodes critiques (creux avril/août), catégories à risque
Prédictif	Anticiper les ruptures sur les produits dont le stock baisse fortement
Prescriptif	Réapprovisionner les top 10, alertes automatiques sous seuil critique

Actions recommandées :

- Anticiper les réapprovisionnements pour les 10 produits les plus critiques
- Surveiller les périodes où le stock diminue fortement (avril, août)
- Optimiser la répartition du stock entre les types d'entrepôts
- Mettre en place des alertes automatiques lorsque le stock passe sous le seuil critique

Section Cost-Down — Réduction des Coûts

Stack technique

Composant	Détail
Données	CSV : warehouses, accounting, logistics
ETL	Power Query / Python (normalisation en-têtes, conversions types, calculs indicateurs)
Modèle	Modèle en étoile — 2 tables de faits + dimensions partagées
Mesures	DAX : Énergie/m ² , L/100km, Coût carburant €, Shrinkage %, % Justificatifs
Restitution	Power BI Desktop & Service (dashboards interactifs, filtres, partages)

Rapport ETL — Nettoyage et transformations

Synthèse globale des fichiers traités

Fichier	Lignes avant	Lignes après	Principales actions
accounting.csv	15 000	15 000	IDs invalides (BADID), doublons, valeurs manquantes, catégories aberrantes
store_maintenance.csv	3 000	3 000	Dates aberrantes (2099), IDs invalides, outliers
budget_forecast.csv	5 600	5 600	IDs invalides, catégories aberrantes, outliers (percentile 99)
warehouses.csv	180	180	Doublons, catégories aberrantes, taux d'occupation hors [0,1]
supplier_orders.csv	8 000	8 000	Valeurs sentinelles, dates aberrantes, cohérence logique
logistics.csv	1 000	1 000	NaN intentionnels (trains), cohérence inter-colonnes, outliers CO ₂ /km

Opérations de nettoyage réalisées

Action	Description	Objectif
Standardisation des schémas	Minuscules, trim, suppression BOM/ÿ	Uniformiser les noms de colonnes
Conversion des types	Dates, montants, km, litres, CO ₂ , surface, occupation	Assurer la cohérence du modèle
Qualité des IDs	Marquage ENT_UNKNOWN / BADID → remplacement par ID généré	Préserver les données financières
Centres de coûts	Suppression NON_RENSEIGNE, inconnu, Narnia	Fiabiliser l'analyse budgétaire

Calculs et indicateurs créés

Indicateur	Formule / Description
Énergie/m ²	monthly_energy_cost / surface_sqm
L/100km	fuel_consumption_l / km_traveled × 100
Coût carburant	fuel_consumption_l × fuel_price_per_l
Δ durée	durée_réelle - durée_planifiée
Shrinkage %	MAX(transporté - reçu, 0) / transporté
% Justificatifs	nb lignes receipt = TRUE / total lignes

Grain, tables de fait et dimensions

Définition des grains

FactLogistics : 1 ligne = 1 trajet (trip_id)

Objectif : réduire L/100km de 5% et CO₂ corrélé · améliorer la ponctualité

FactAccounting : 1 ligne = 1 dépense (expense_id)

Objectif : porter les justificatifs à 95% · fiabiliser les centres de coûts · suivre l'OPEX

Tables de dimensions

Dimension	Contenu	Utilité analytique
DimDate	Date, année, trimestre, mois, fiscal	Suivi temporel des coûts et dépenses
DimWarehouse	ID, pays, ville, type, surface, capacité	Analyse par site, top hotspots énergie
DimTransportMode	Mode de transport (camion, train...)	Comparaison consommation et CO ₂
DimExpenseType	Type de dépense	Analyse OPEX par catégorie
DimCostCenter	Centre de coût	Fiabilisation et suivi budgétaire
DimRelatedEntity	Entité liée à la dépense	Traçabilité comptable

Mesures DAX

Mesure DAX	Formule
Énergie (€/mois)	SUM(Warehouses[monthly_energy_cost])
Énergie/m² (€)	DIVIDE([Énergie], SUM(Warehouses[surface_sqm]))
Km total	SUM(Logistics[km_traveled])
L/100km	DIVIDE(SUM([fuel_consumption_l]), [Km total]) * 100
Coût carburant €	SUMX(Logistics, [fuel_consumption_l] * [fuel_price_per_l])
Shrinkage %	DIVIDE(MAX(transporté - reçu, 0), transporté)
% Justificatifs	DIVIDE(COUNTROWS(FILTER(Accounting, receipt = TRUE()))), COUNTROWS(...))

Schéma relationnel




FIGURE 9 – Schéma relationnel — Analyse Cost-Down (Power BI)

Les relations du modèle en étoile :

- DimDate → FactLogistics via **trip_date** (1 à N)
- Warehouses → FactLogistics via **departure_warehouse_id** (1 à N)
- FactLogistics → DimExpenseType via **expense_type** (N à 1)
- Accounting → DimCostCenter via **cost_center** (N à 1)

Dashboards et interprétation

Dashboard 1 — Synthèse exécutive Cost-Down




FIGURE 10 – Dashboard — Synthèse exécutive · Trajectoire de baisse des coûts

Interprétation : Le dashboard exécutif présente les 3 KPIs stratégiques : énergie à **2 576k€/mois** (objectif -10%), L/100km à **5,01%** (objectif -5%), justificatifs à **95%** (-1pt). Le graphique d'énergie mensuelle vs cible montre une tendance baissière encourageante mais encore au-dessus de la cible (ligne pointillée). L'OPEX est dominé par les salaires (200K€) et le loyer (160K€). Concernant les émissions CO₂, le camion génère environ 3 fois plus d'émissions que le train, confirmant l'intérêt de la bascule rail pour les trajets longs.

Dashboard 2 — Entrepôts & Énergie




FIGURE 11 – Dashboard — Entrepôts & Énergie

Interprétation : Le coût énergétique moyen s'établit à **5,02€/m²** avec un coût mensuel global de 2 621k€ (objectif -10%). Le nuage de points Occupation % vs Énergie/m² révèle que plusieurs sites consomment plus de 6€/m² pour une occupation inférieure à 40% — ces sites sont les **hotspots prioritaires** à optimiser. Le top 5 des sites les plus coûteux affiche des valeurs entre 4 et 7€/m², soit 40% au-dessus de la moyenne. Les actions recommandées sont : consignes froid, remplacement LED, coupure des veilles, renégociation des contrats énergie.

Dashboard 3 — Logistique (Carburant & CO₂)




FIGURE 12 – Dashboard — Logistique · Carburant & CO₂

Interprétation : Le dashboard logistique affiche **9 105K km/mois** avec une consommation de **34,5L/100km** (objectif –5%) pour un coût carburant de **5 091k€**. La courbe L/100km montre une légère amélioration de janvier à août mais reste au-dessus de la cible (ligne pointillée). Le comparatif camion vs train confirme que le train est plus efficace tant en consommation qu'en CO₂. Le coût carburant progresse de 200€ en janvier à 500€ en novembre, signalant une inefficacité croissante à corriger via l'écoconduite et la consolidation des tournées.

BI descriptive au call to action

Niveau BI	
Application au projet Cost-Down	
Descriptif	Mesurer : énergie/mois, L/100km, OPEX, CO ₂ , Shrinkage, % justificatifs
Diagnostic	Expliquer : hotspots €/m ² , trajets en retard, surconsommations, centres douteux
Prédicatif	Fixer des cibles : –10% énergie, –5% L/100km, 95% justificatifs
Prescriptif	Quick wins énergie, consolidation tournées, bascule rail, écoconduite
Pilotage	Comité mensuel cost-down, backlog d'actions, suivi des gains dans Power BI

Plan de baisse des coûts :

- **Énergie** : viser -10% via traitement prioritaire des hotspots €/m² (quick wins + renégociation contrats)
- **Logistique** : -5% L/100km par écoconduite, entretien pneus, consolidation des tournées, bascule rail pour trajets $>250\text{km}$
- **OPEX** : porter les justificatifs à 95% et corriger les centres de coûts pour fiabilité budgétaire